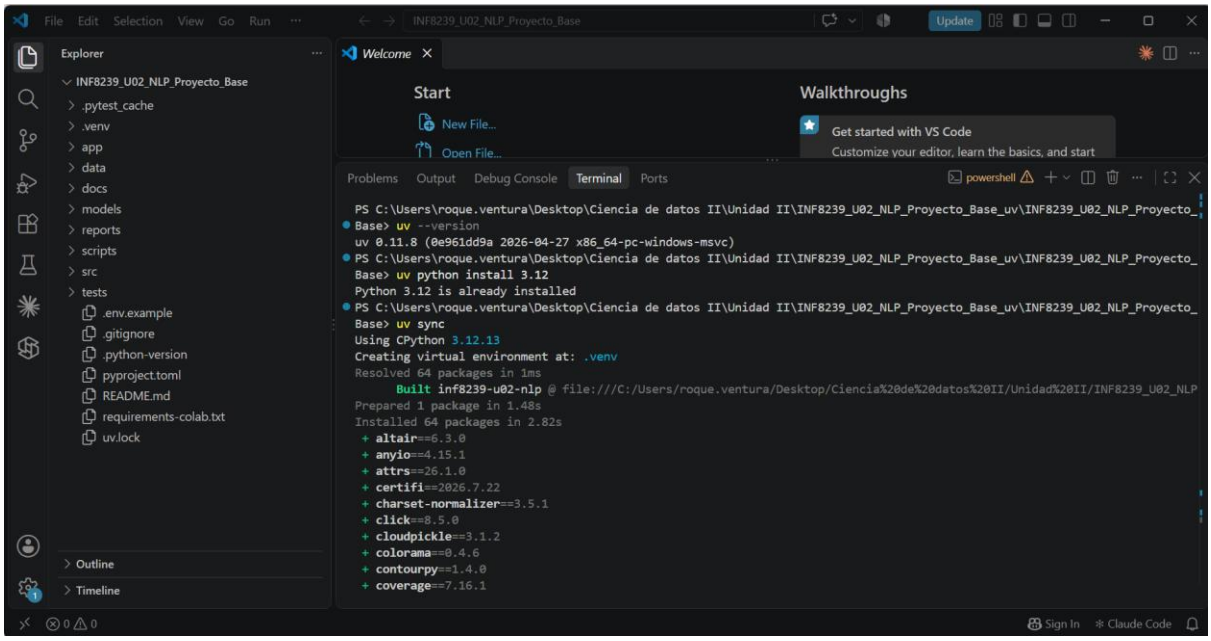
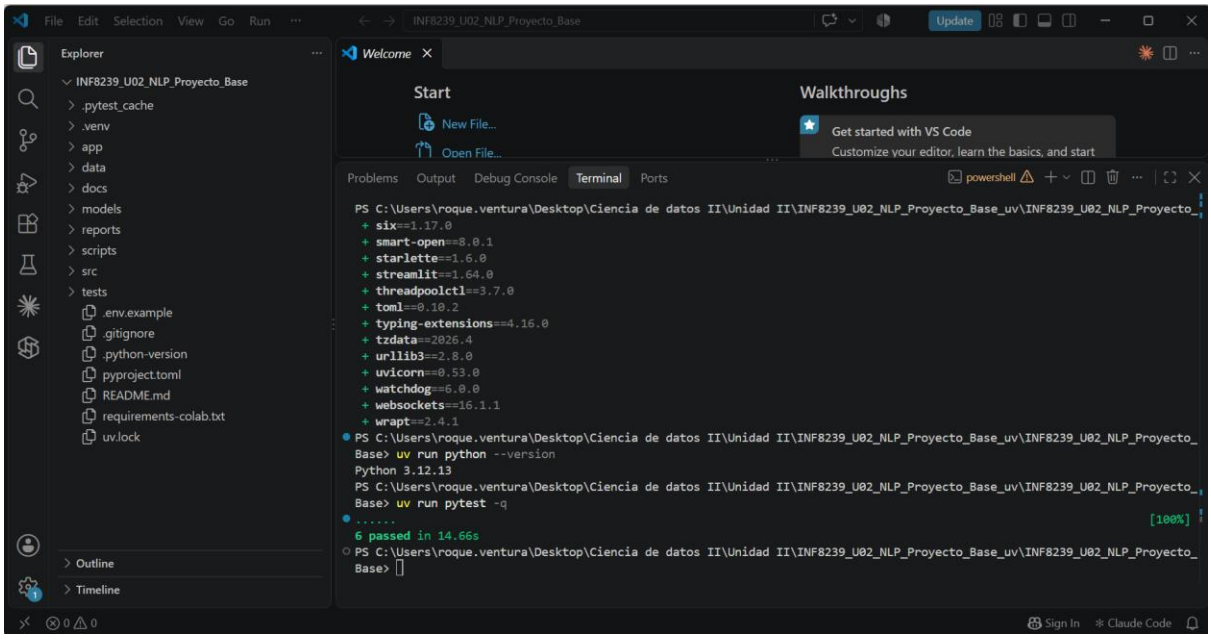
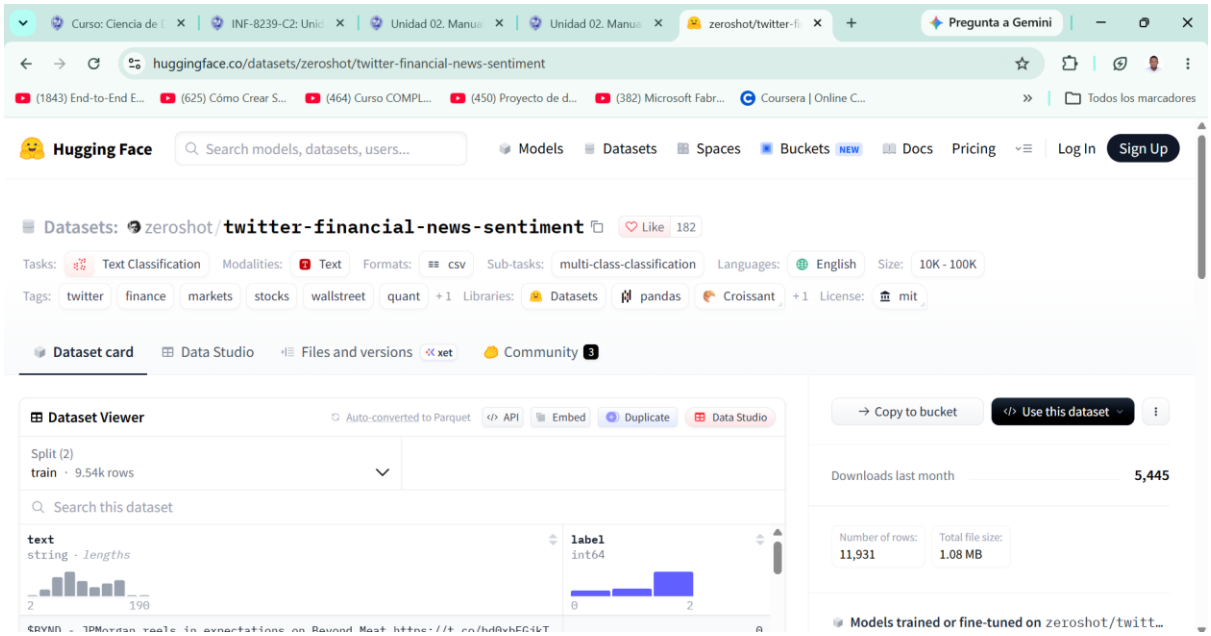
Laboratorio 04



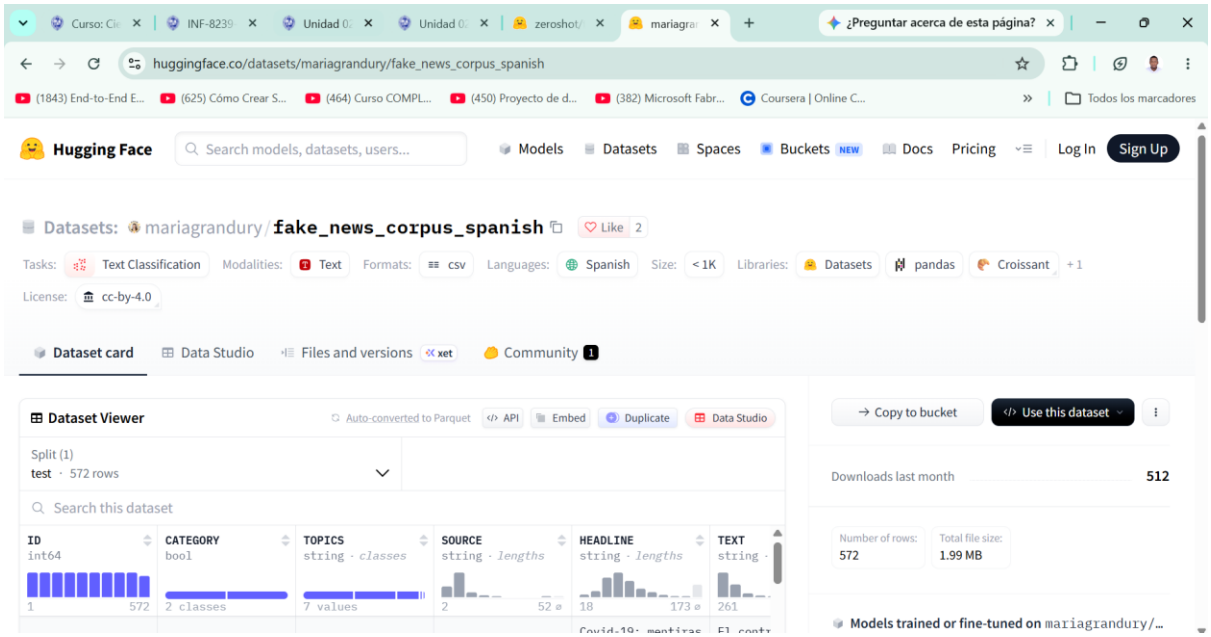
Paso 2 · Entorno con uv. *Se verifica uv, Python 3.12 ya instalado y uv sync crea la .venv con las 64 dependencias.*



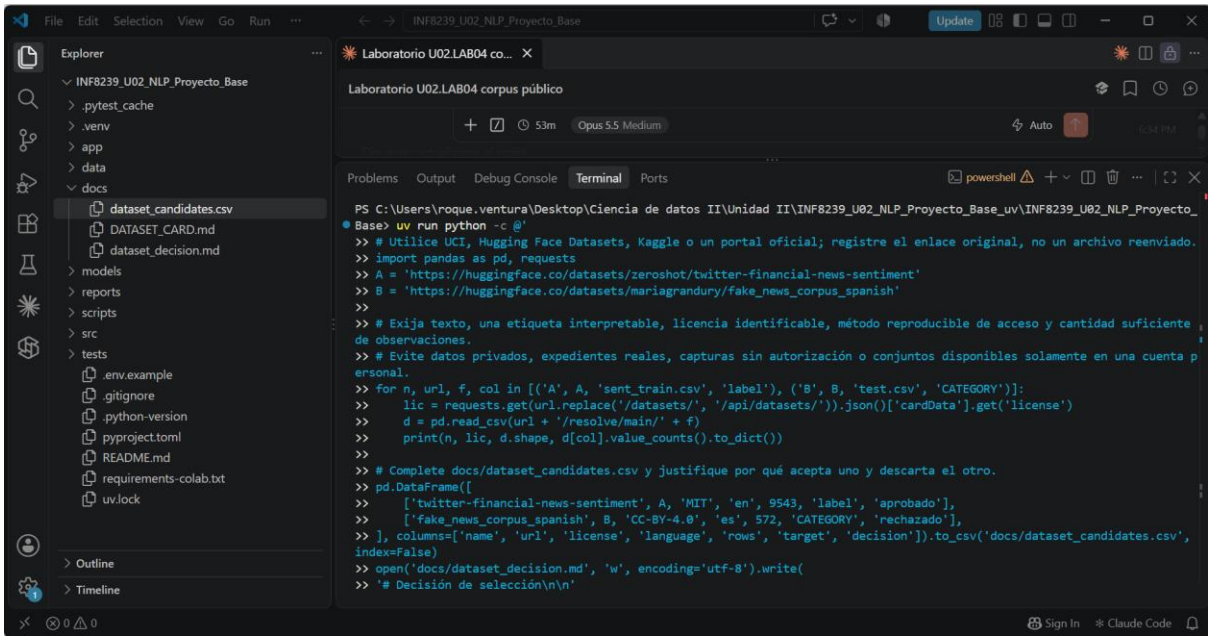
Paso 2 · Verificación del entorno. *uv run python --version muestra Python 3.12.13 y uv run pytest -q aprueba 6 pruebas.*



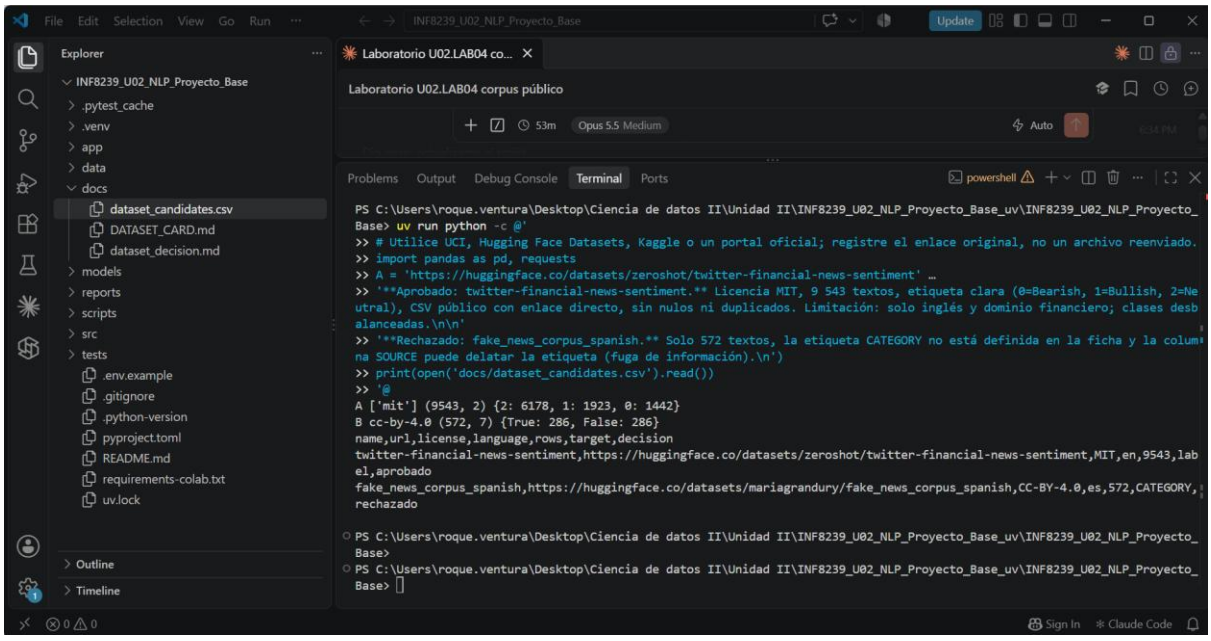
Paso 4 · Candidato A. *twitter-financial-news-sentiment en Hugging Face: texto con etiqueta, CSV, inglés, licencia MIT y 9.54k filas.*



Paso 4 · Candidato B. *fake_news_corpus_spanish en Hugging Face: licencia CC BY 4.0, pero solo 572 filas en un único split "test".*



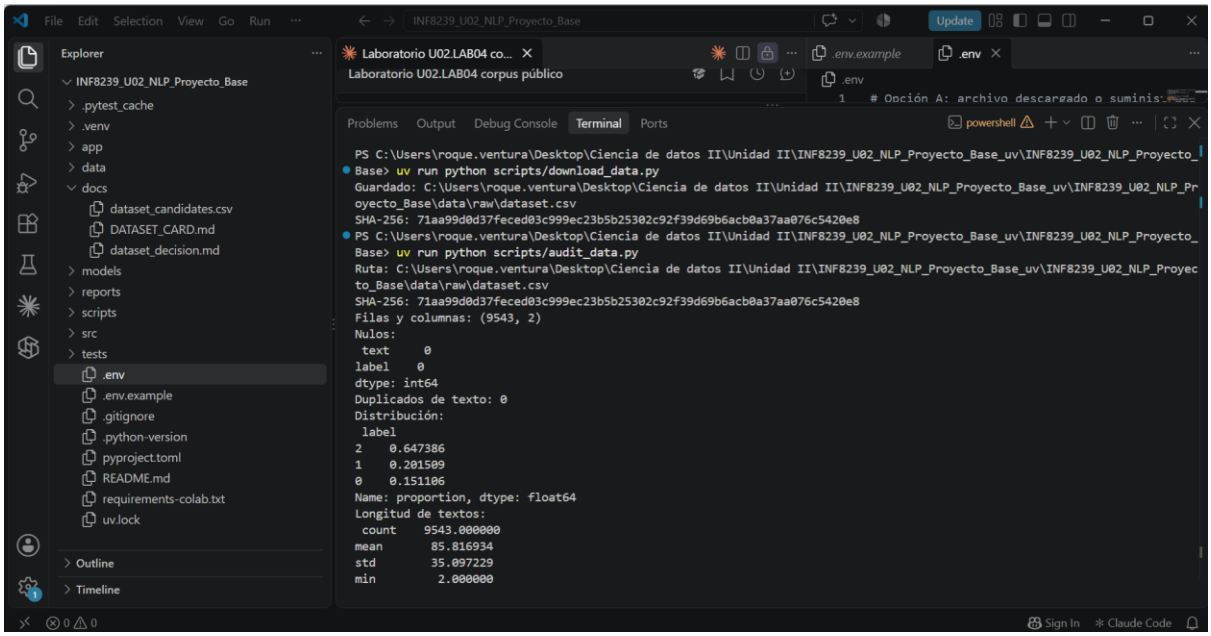
Paso 4 · Comparación de candidatos. *Script que consulta licencia, filas y clases de ambos datasets y completa docs/dataset_candidates.csv.*



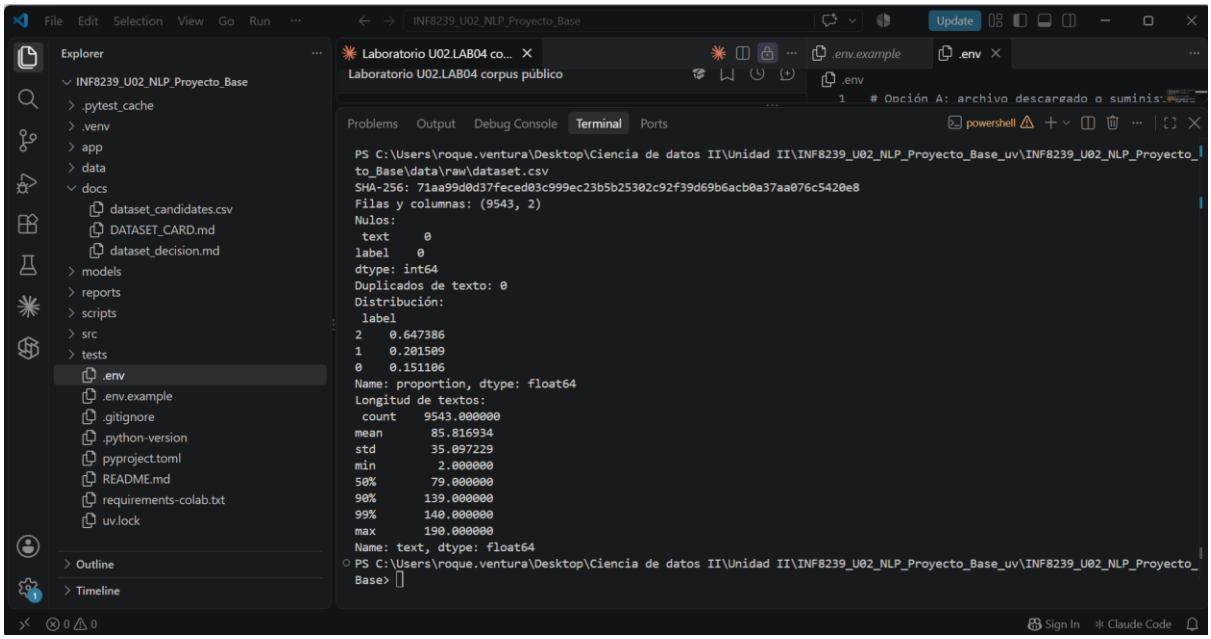
Paso 4 · Resultado de la comparación. *A: MIT, 9 543 filas, 3 clases (aprobado). B: CC BY 4.0, 572 filas (rechazado).*

Criterio	Respuesta
Pertinencia	Sí. Cada texto es un tuit financiero con una etiqueta de sentimiento (Bearish, Bullish o Neutral), así que sirve para responder: *¿se puede predecir el sentimiento de un tuit financiero a partir de su texto?*
Licencia	Sí. Tiene licencia MIT, que permite descargar, analizar y publicar resultados derivados. Limitación: los textos vienen de Twitter, que tiene sus propios términos de uso.
Representatividad	Quedan fuera los otros idiomas (solo hay inglés), otras redes y medios (solo Twitter), los temas no financieros y el público general, porque predominan cuentas de noticias y analistas. La ficha no documenta el periodo de recolección.
Calidad	Hay 0 nulos y 0 textos duplicados en 9 543 filas. Las clases están desbalanceadas: Neutral 65 %, Bullish 20 %, Bearish 15 %. Ninguna clase es extremadamente pequeña, pero la accuracy sola sería engañosa. Algunos textos neutrales pueden ser ambiguos.
Reproducibilidad	Sí. Hay un enlace directo público al CSV, sin cuenta personal, y la versión exacta se puede verificar con el hash SHA-256 que genera download_data.py. Riesgo: el autor puede actualizar el repositorio en Hugging Face.
Riesgo	Riesgo bajo. Son tuits públicos con cashtags ($GM) y enlaces t.co. Pueden aparecer nombres de cuentas o empresas, pero no hay datos personales sensibles evidentes. Un modelo entrenado con estos datos no debería usarse para tomar decisiones de inversión.

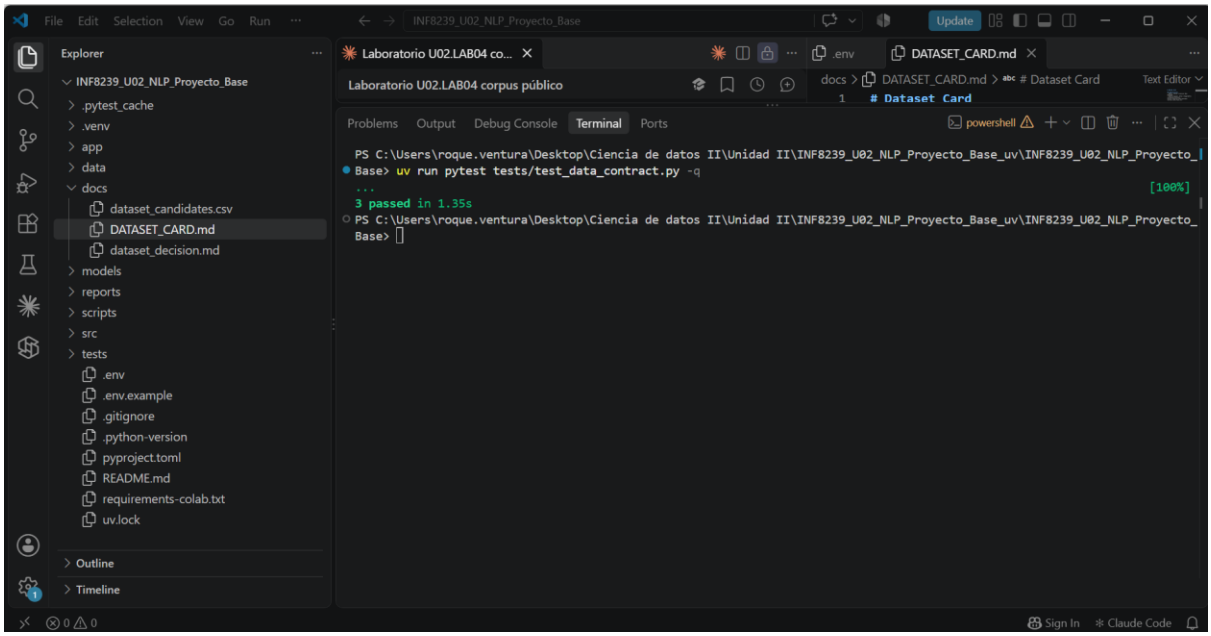
El candidato rechazado (fake_news_corpus_spanish) falla en **calidad** (solo 572 filas) y en **pertinencia**, porque la etiqueta no está definida en la ficha.



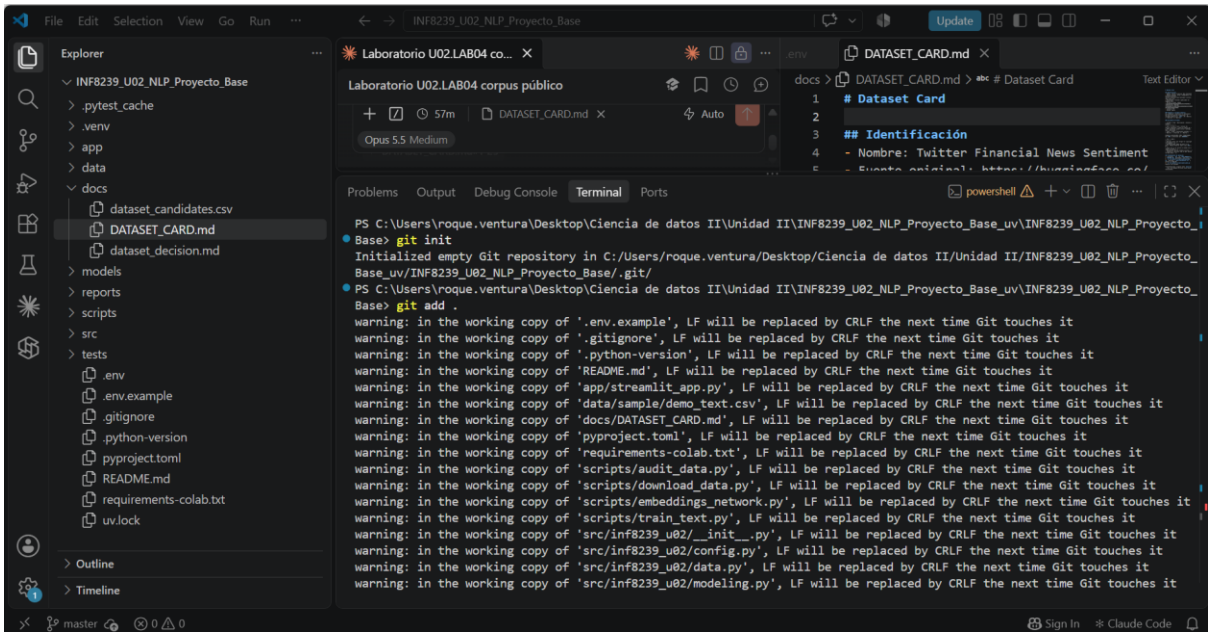
Paso 6 · Descarga y auditoría. *download_data.py guarda el CSV y muestra el SHA-256; audit_data.py reporta 9 543 filas, 0 nulos y 0 duplicados.*



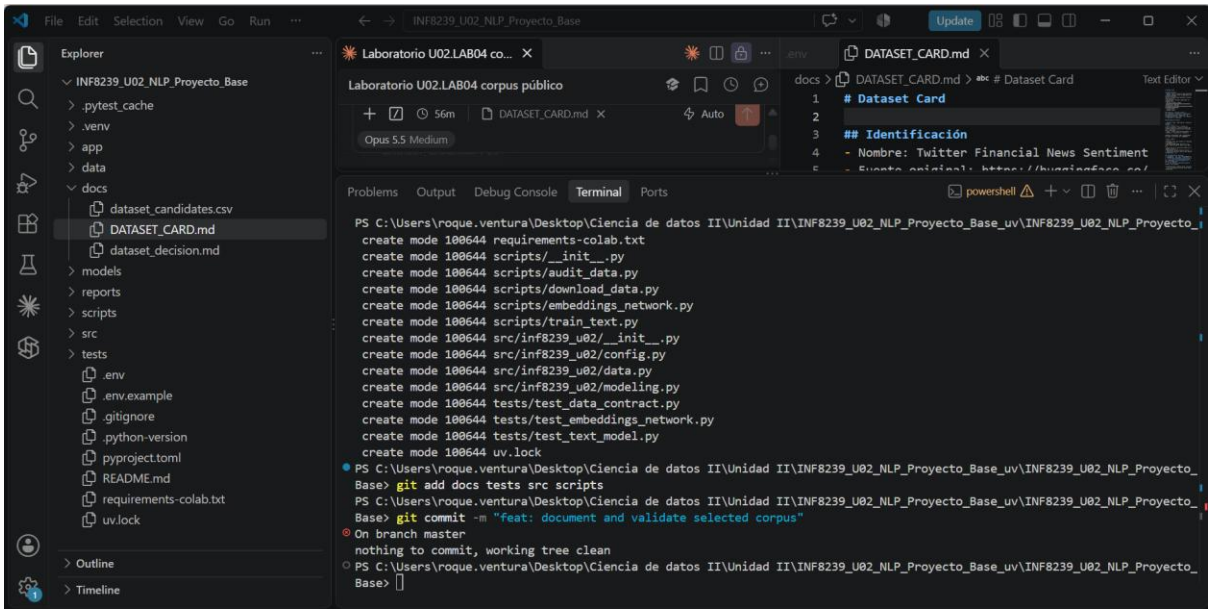
Paso 6 · Auditoría (continuación). *Clases desbalanceadas (Neutral 64.7 %) y longitud de textos p50 = 79, p90 = 139, p99 = 140.*



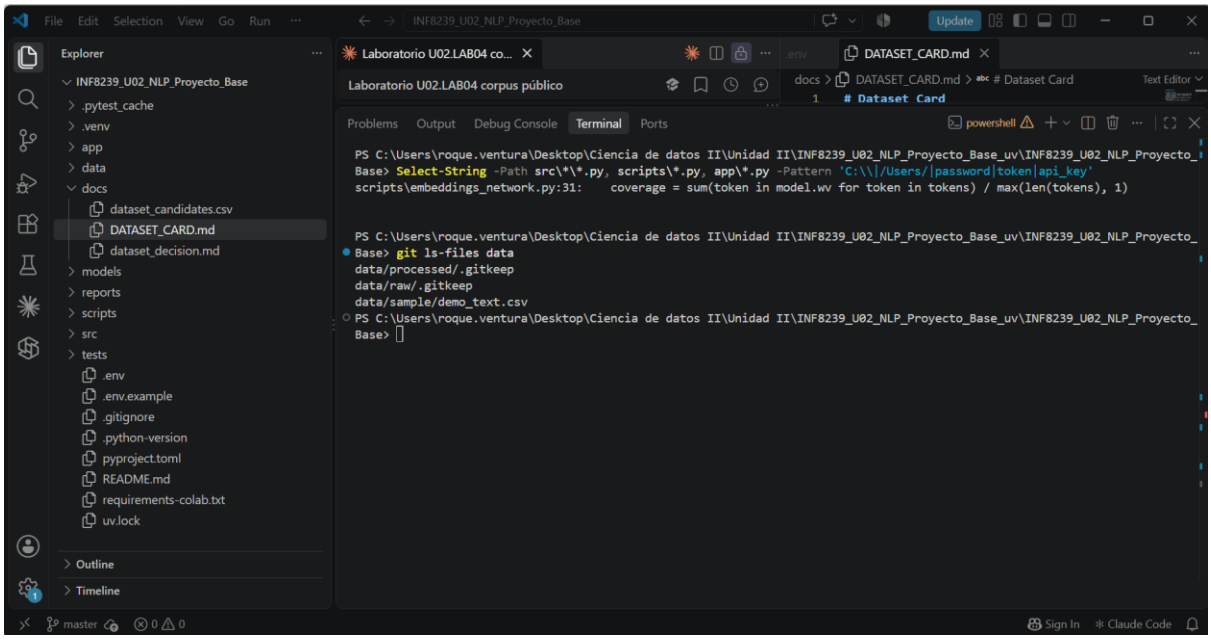
Paso 8 · Contrato de datos. *tests/test_data_contract.py aprueba sus 3 pruebas de validación.*



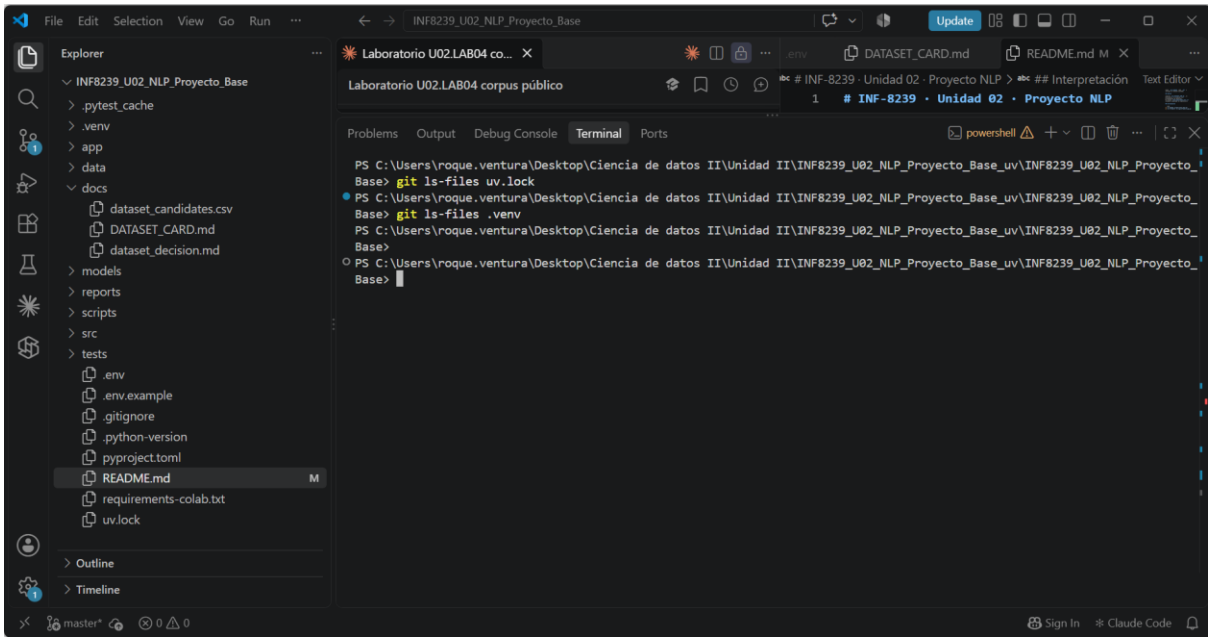
Paso 9 · Registro con Git. *git init y git add . inicializan el repositorio (los avisos LF/CRLF son normales en Windows).*



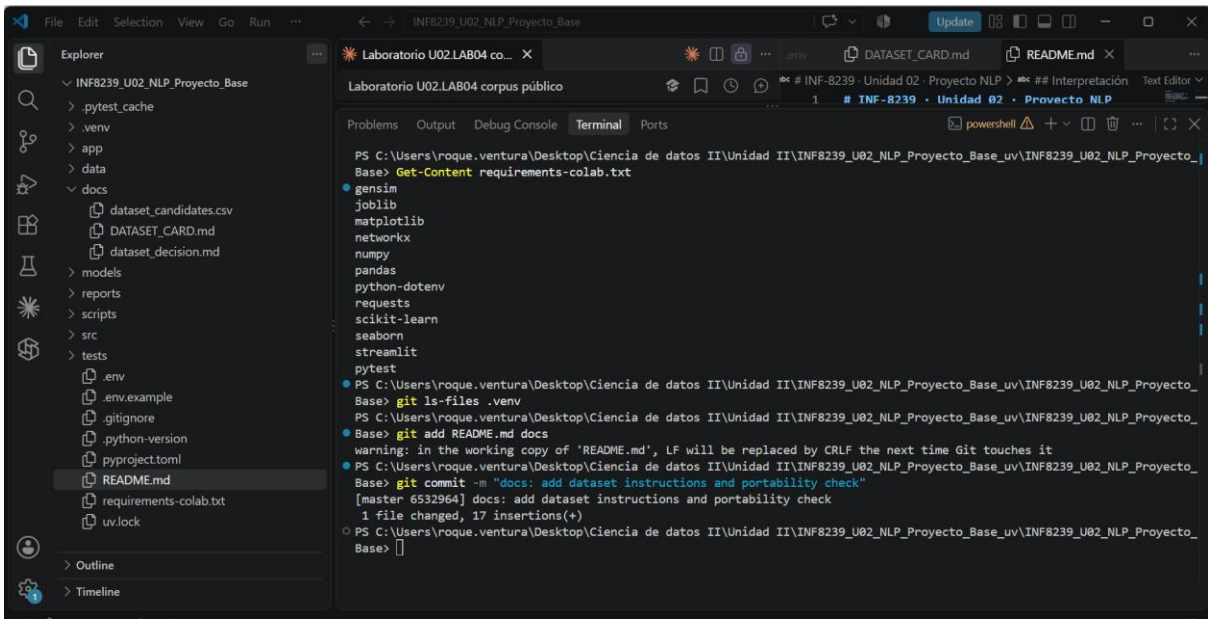
Paso 9 · Commits. *Primer commit creado; el segundo no tuvo cambios porque docs, tests, src y scripts ya estaban incluidos.*



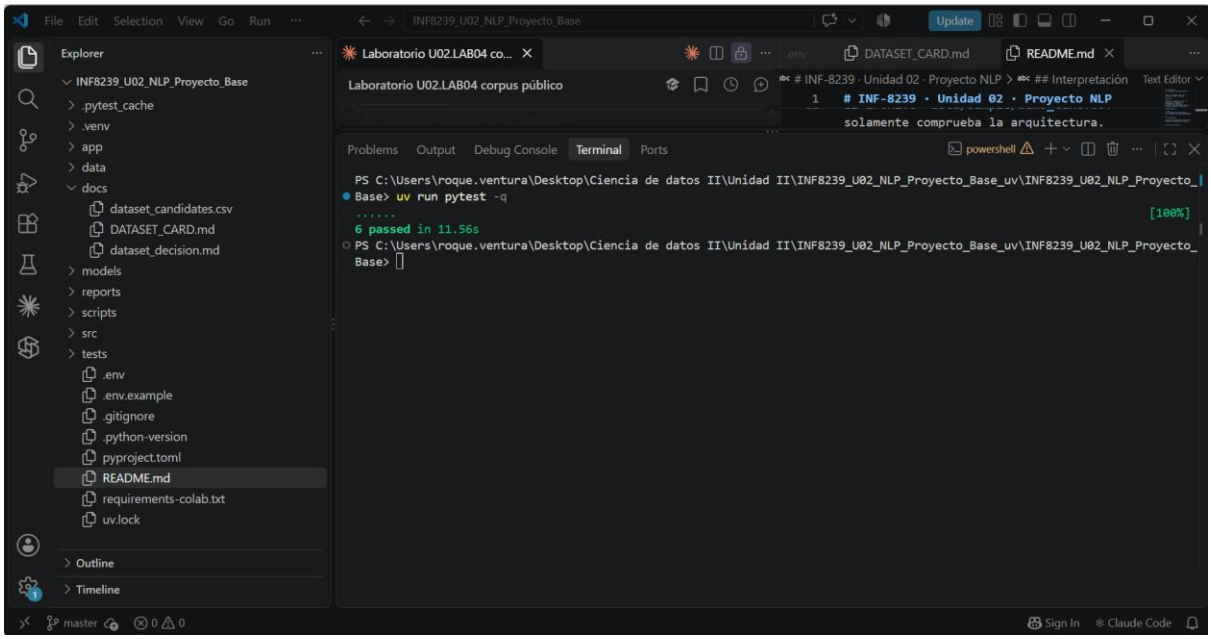
Paso 10 · Portabilidad. *Sin rutas absolutas ni credenciales en el código ("token" es la variable de tokenización) y data/raw no está en Git.*



Paso 10 · Exclusión de .venv. *git ls-files .venv no devuelve nada: el entorno virtual no se versiona.*

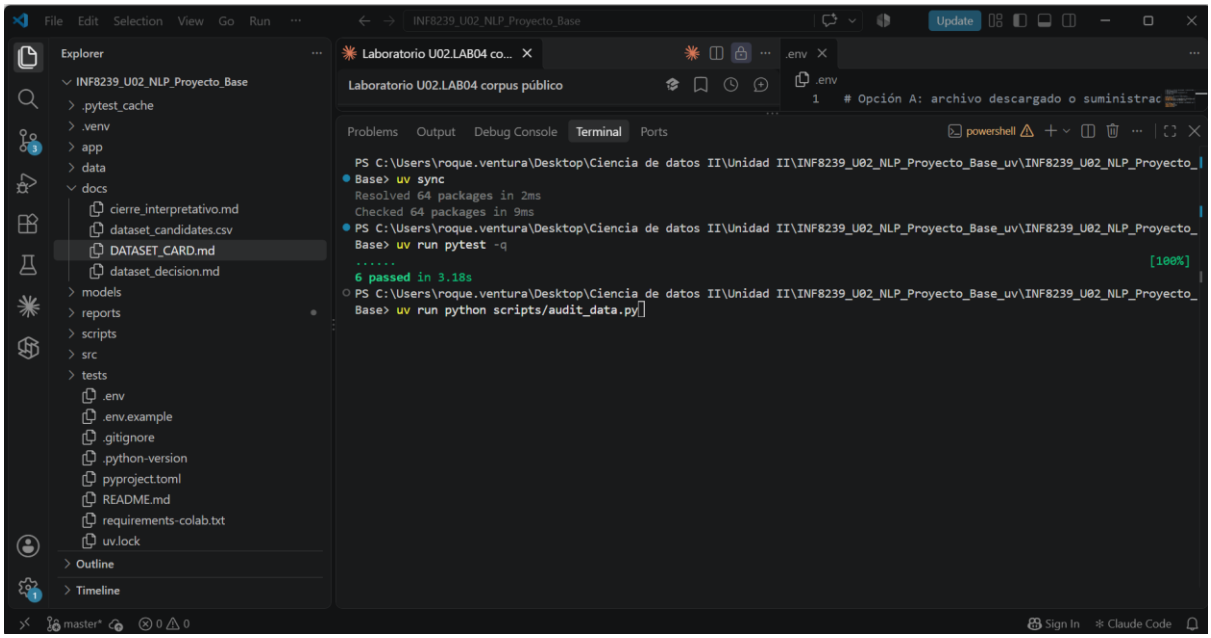


Paso 10 · Colab y README. *requirements-colab.txt lista las dependencias para Colab y se hace commit del README con las instrucciones del dataset.*

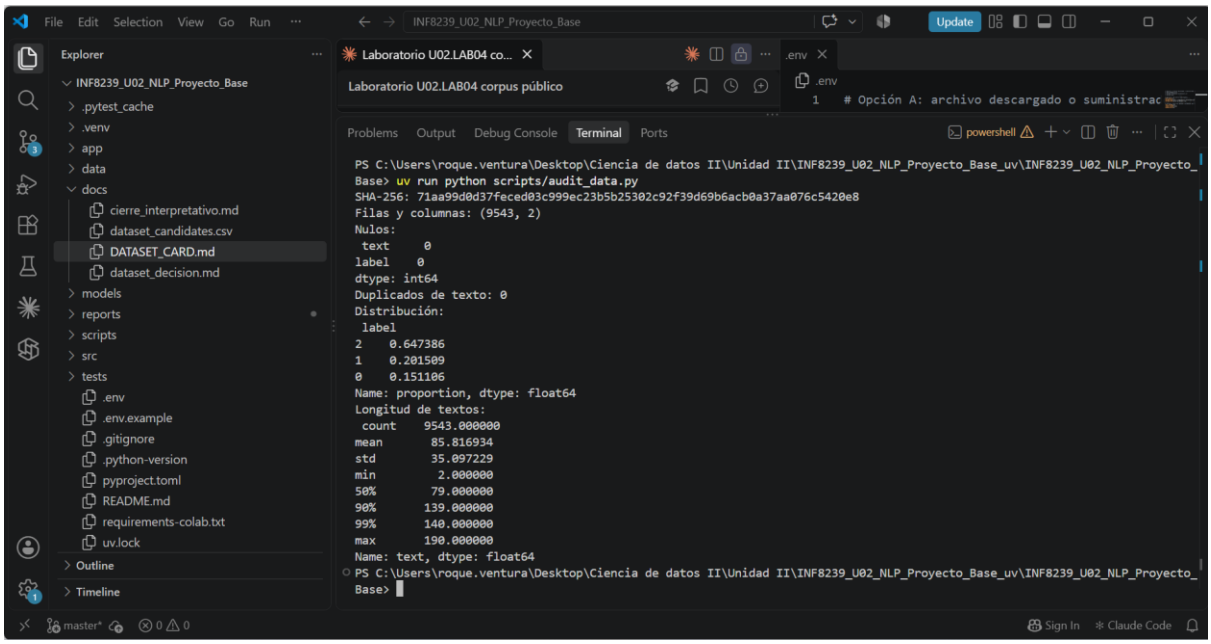


Finalización. *uv run pytest -q se ejecuta nuevamente: 6 pruebas aprobadas.*

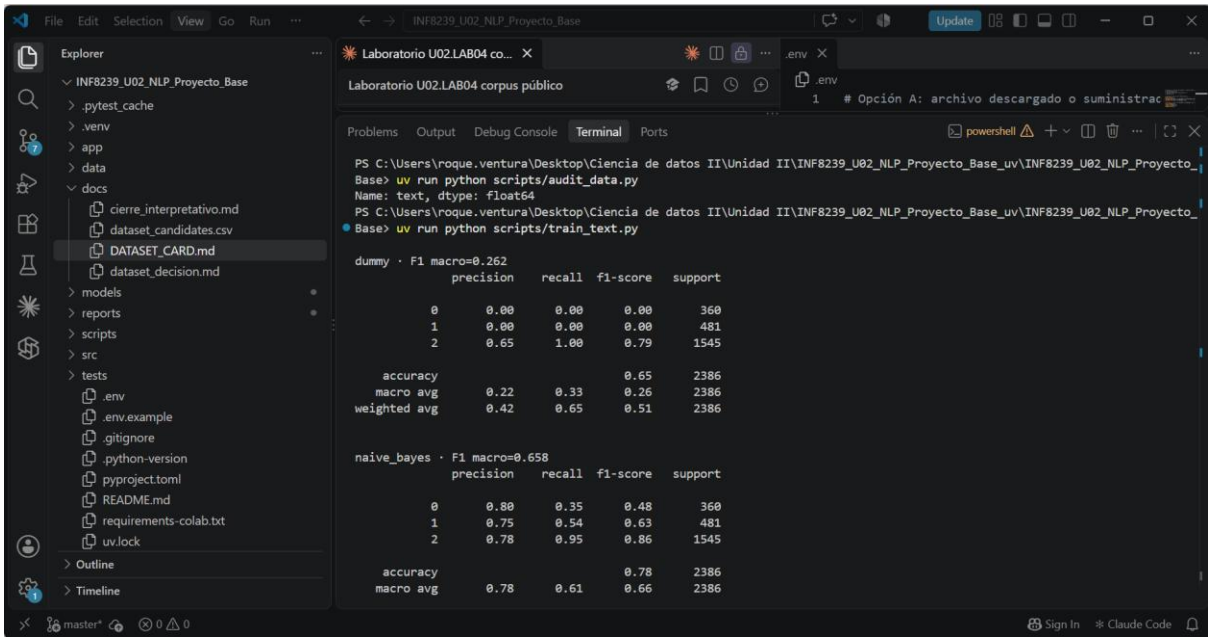
Laboratorio 05



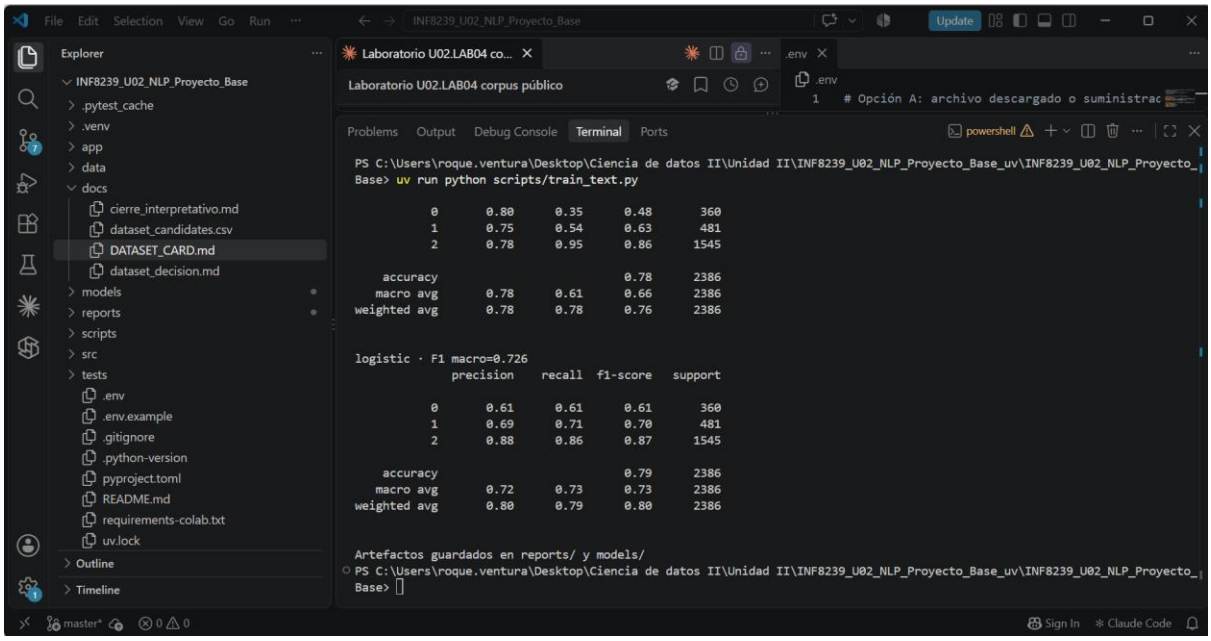
Paso 2 · Sincronizar y verificar. *uv sync sin cambios y uv run pytest -q con 6 pruebas aprobadas antes de entrenar.*



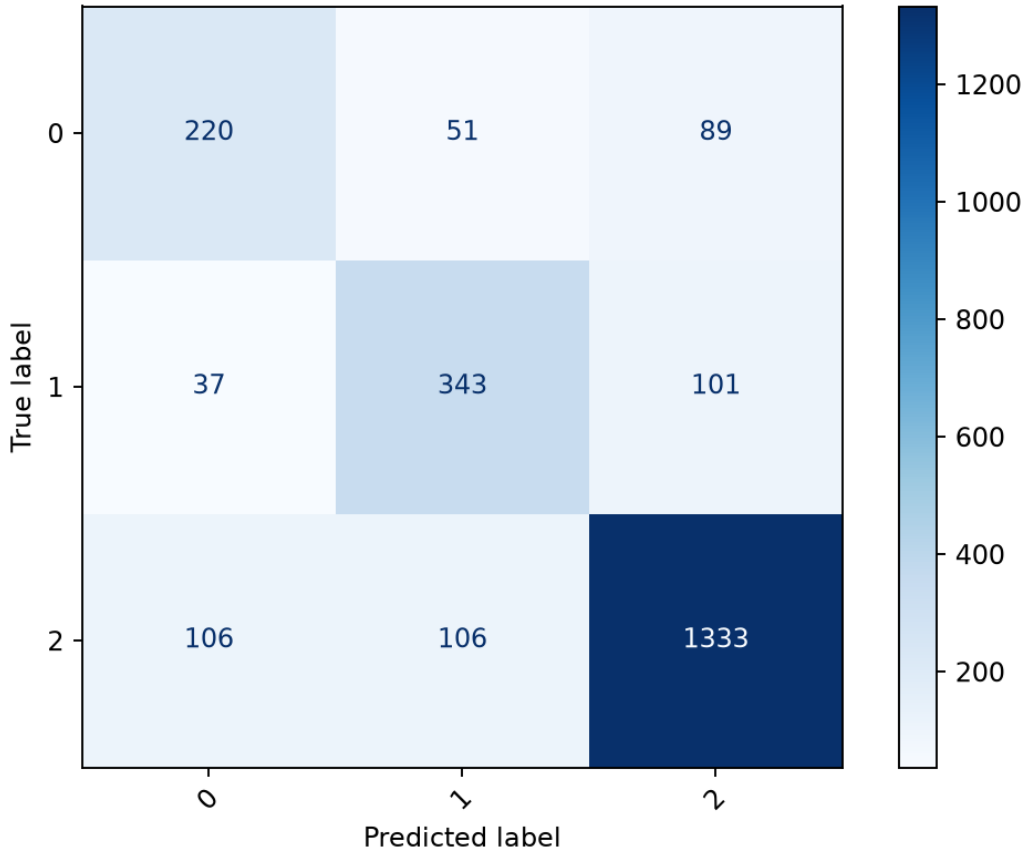
Paso 2 · Auditoría previa. *Sin nulos ni duplicados y con 3 clases: el corpus cumple las condiciones para entrenar.*



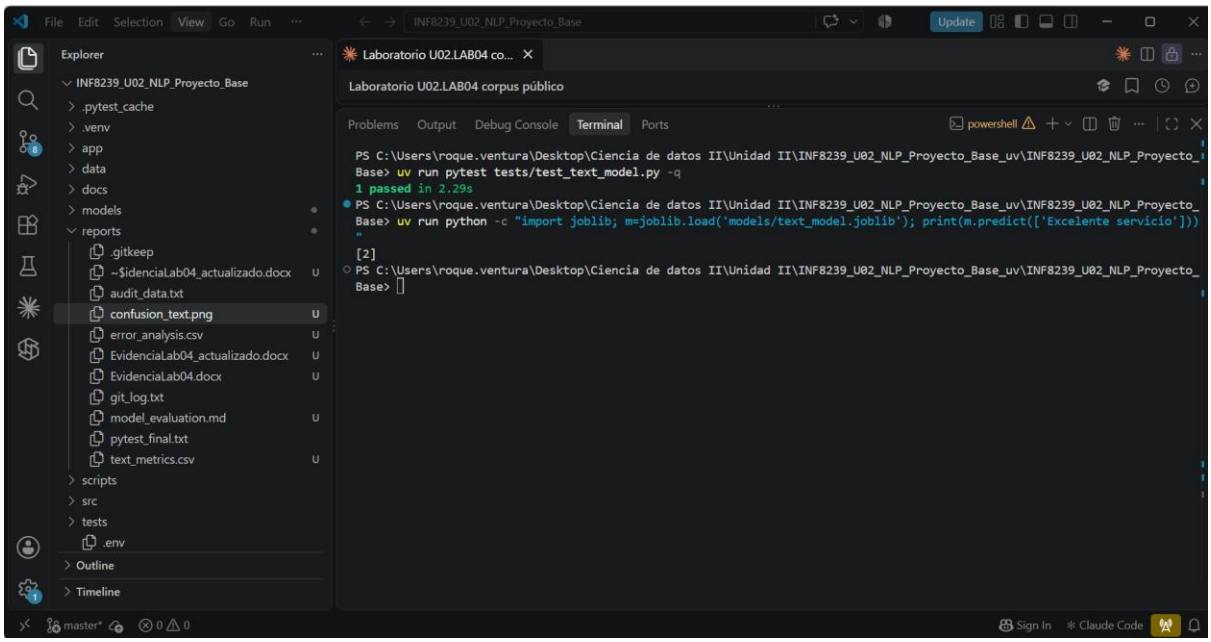
Paso 3 · Entrenamiento. *train_text.py entrena los tres pipelines: Dummy (baseline) F1 macro 0.262 y Naive Bayes 0.658.*



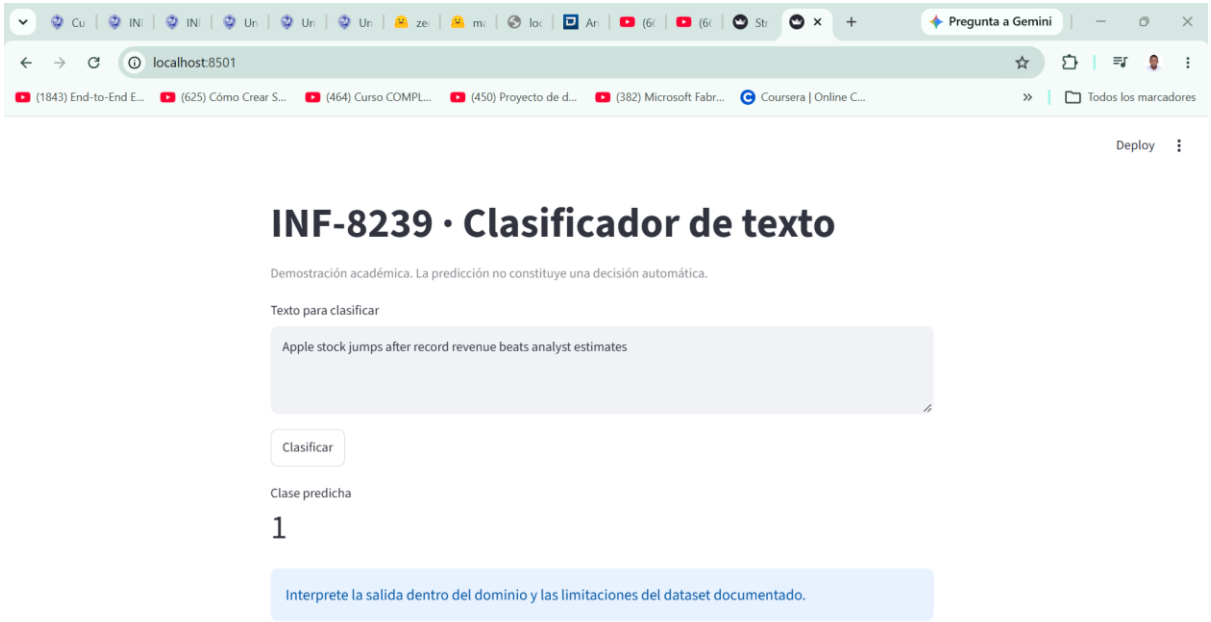
Paso 3 y 4 · Regresión logística. *Mejor F1 macro (0.726); Bearish (0) tiene el menor recall (0.61). Se guardan los artefactos en reports/ y models/.*



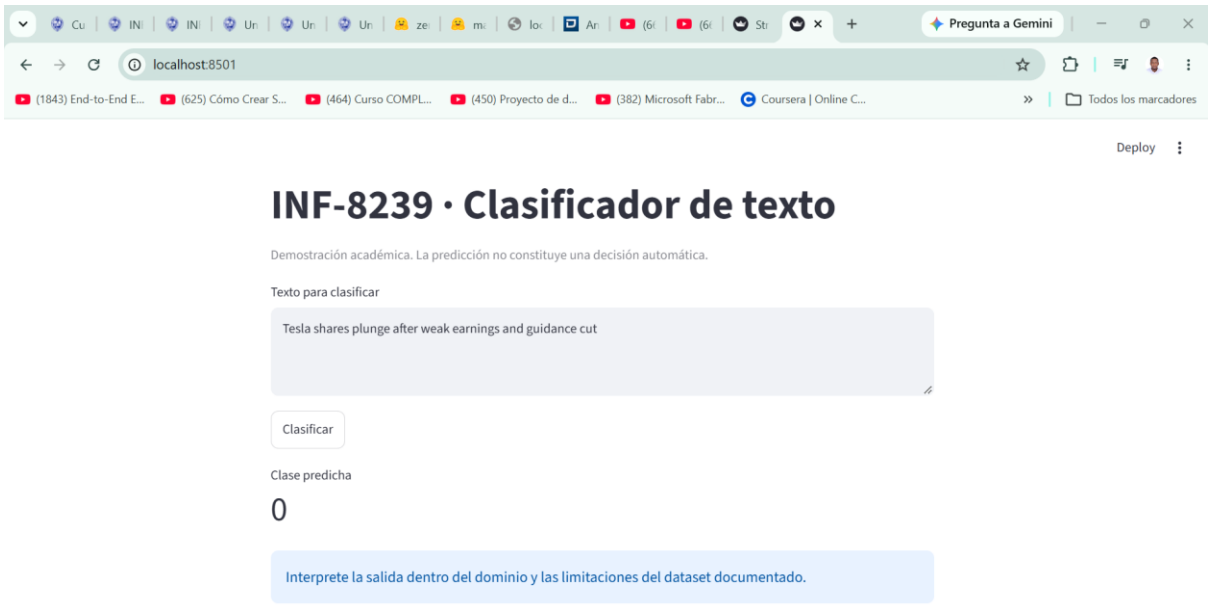
Paso 5 · Matriz de confusión. *Diagonal: 220, 343 y 1 333 aciertos. Mayor confusión: Neutral predicho como Bearish y como Bullish (106 cada una).*



Paso 7 · Pruebas y modelo guardado. *test_text_model.py aprueba; el modelo cargado predice 2 (Neutral) para "Excelente servicio", un texto fuera del dominio.*



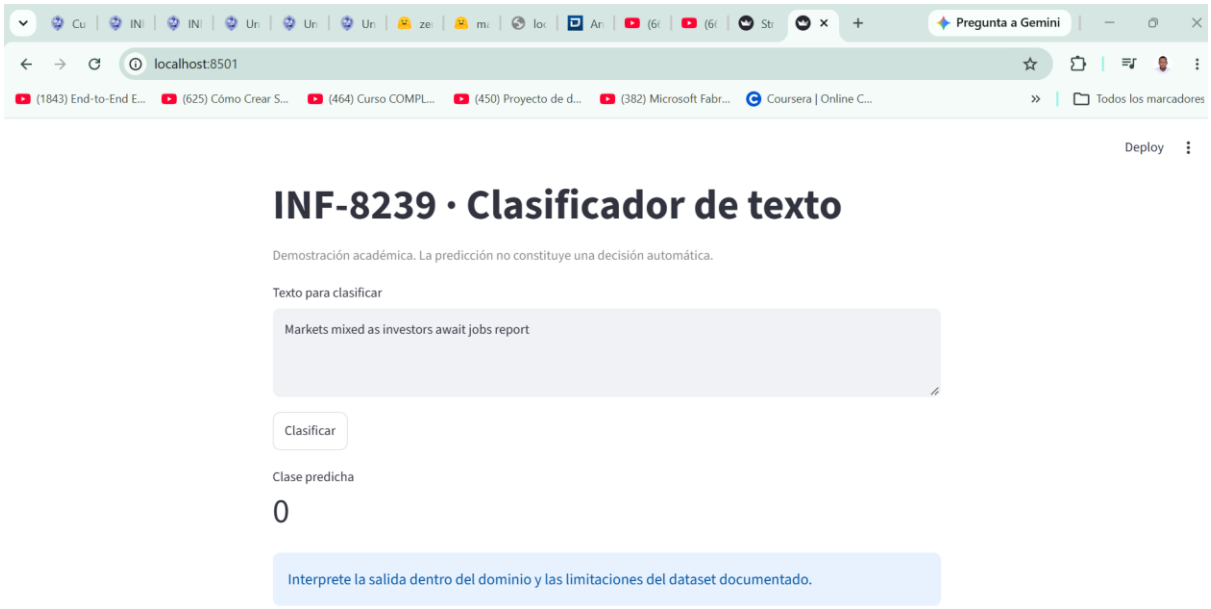
Paso 8 · App con texto claro. *"Apple stock jumps...": el modelo predice 1 (Bullish). La advertencia de alcance es visible.*



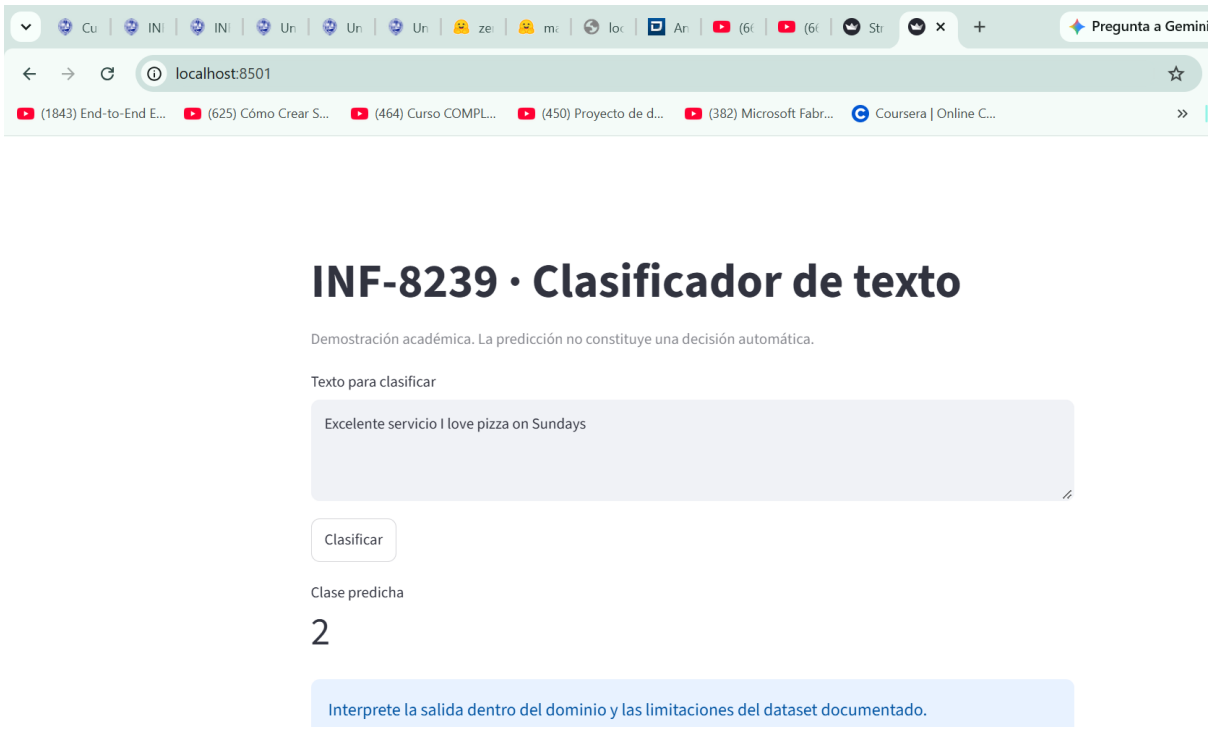
Paso 8 · App con texto claro. *"Tesla shares plunge...": el modelo predice 0 (Bearish).*



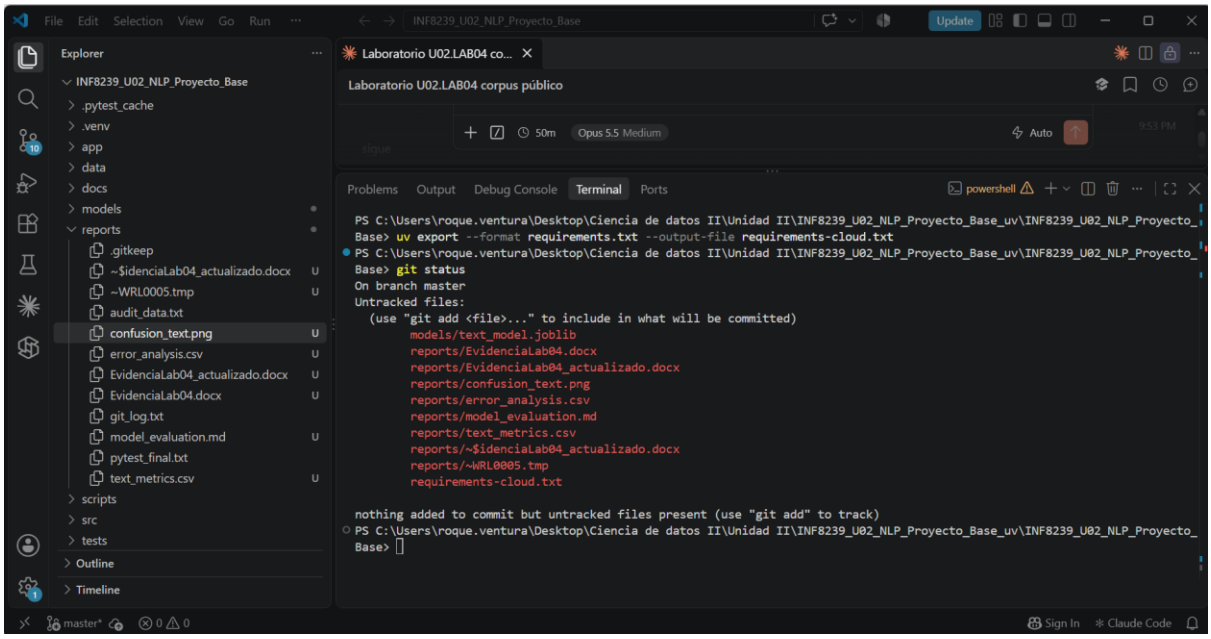
Paso 8 · App con texto neutral. *"Federal Reserve to announce...": el modelo predice 2 (Neutral).*



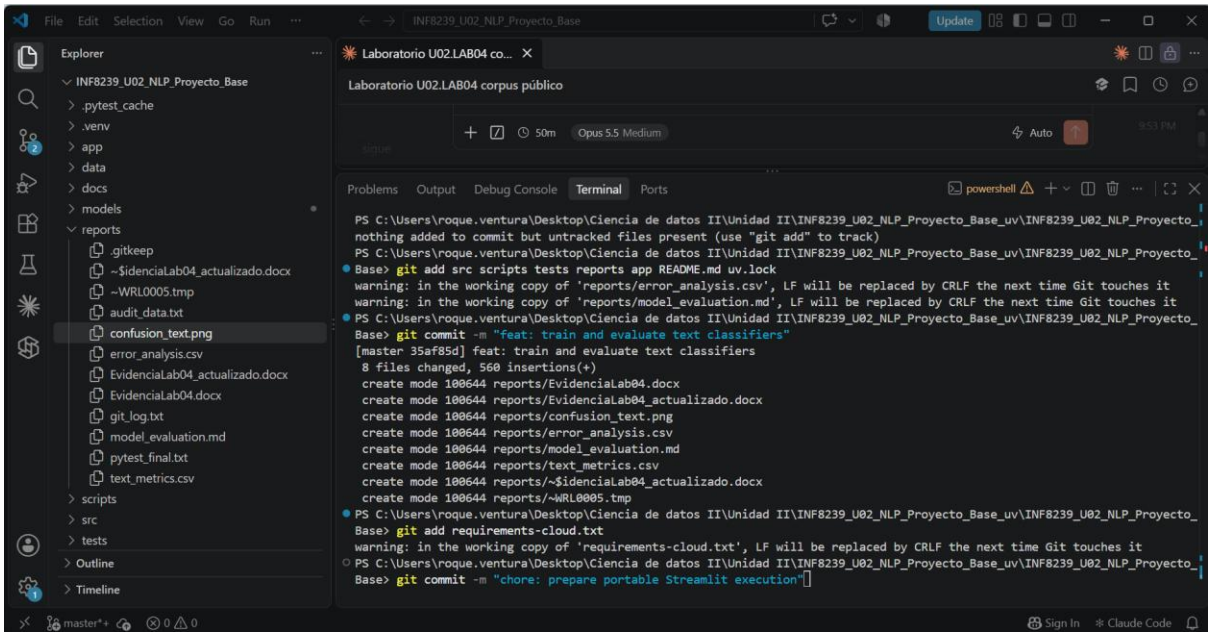
Paso 8 · Frase ambigua. *"Markets mixed as investors await jobs report": el modelo predice 0 (Bearish), lo que muestra su fragilidad ante textos ambiguos.*



Paso 8 · Fuera del dominio. *Texto no financiero: el modelo igual devuelve 2 (Neutral). La salida es una predicción condicionada por los datos, no una verdad.*



Paso 9 · Preparación para la nube. *uv export genera requirements-cloud.txt y git status muestra el modelo y los reportes pendientes de registrar.*



Paso 10 · Registro con Git. *Commit "feat: train and evaluate text classifiers" y commit de requirements-cloud.txt para la ejecución portable.*