Ejercicio 07: Evaluación de impacto y auditoría de equidad

INF-8239 Ciencia de Datos II, Unidad 04 (U04.E07)

Estudiante	Roque Alexis Ventura Vallejo
Matrícula	100805873
Repositorio	github.com/RoqueVentura/UASD-Maestria-Ciencia-De-Datos, Ciencia de datos II/Unidad IV/Ejercicio 07
Evidencia	U04_E07_Evidencias_Roque_Ventura.pdf (abrir en GitHub)
Base	LAB11 y LAB12, proyecto INF8239_U04_Gobernanza_DSS_Proyecto_Base_uv (uv, Python 3.12, scikit-learn 1.9.1, fairlearn 0.12.0, en CPU)
Decisión final	**Modificar y limitar**: modelo mitigado solo en piloto con revisión humana de todos los casos (sección 8)

1. Caso, alcance y evidencia

El caso es el **Territorial Review DSS**, un sistema de apoyo a decisiones que ordena casos territoriales para que un analista decida cuáles revisar primero. Los datos son sintéticos: 640 casos con zona, grupo protegido (G1, G2), tramo de edad, incidentes previos, índice de infraestructura, exposición y una etiqueta binaria. No representan personas, territorios ni estadísticas reales de la República Dominicana.

Este expediente integra LAB11 (evaluación de impacto ético) y LAB12 (auditoría de equidad). Añade un análisis propio de mitigación e incertidumbre que el laboratorio no incluía. Cada cifra sale de un archivo del repositorio: CSV, YAML o JSON editables, generados por scripts con semilla 42 y verificados por 12 pruebas. El anexo de evidencias contiene las capturas de LAB11 (E1–E3) y la salida de consola de LAB12 y E07 (*reports/e07/run_log.txt*).

2. Finalidad, interesados y proporcionalidad

Ficha de propósito tomada de *student_inputs/lab11_impact.yml*:

Finalidad	Priorizar casos territoriales sintéticos para revisión humana; solo recomienda un orden, no decide.
Decisión asistida	Orden en que el analista revisa la cola de casos; la decisión final siempre es humana.
Usuarios	Analistas territoriales capacitados y su supervisor.
Población afectada	Personas y hogares de las zonas cuyos casos entran en la cola, en especial grupos protegidos y personas de 60+.
Propietario	Dirección de Gestión de Riesgo Territorial.
Alternativa no predictiva	Revisión por orden de llegada (FIFO) con reglas simples y públicas, sin modelo. Para medirla la concreté como reglas explícitas: prioridad si *previous_incidents* ≥ 3 o *infrastructure_score* < 0.3.
Uso fuera de alcance	Intervención automática, decidir elegibilidad, declarar emergencias o perfilar personas reales.
Condición de retiro	Suspender si el recall baja de 0.68, si la brecha entre grupos supera 0.16 o si se detecta un uso indebido o un daño.
Apelación	La persona afectada puede pedir revisión humana a un supervisor independiente, que responde en 10 días hábiles.

Partes interesadas (*student_inputs/stakeholders.csv*). El usuario (analista) no es la persona afectada, y quien más daño puede sufrir es quien menos poder tiene:

Actor	Beneficio	Daño posible	Poder	Participación
Persona afectada	Su caso se revisa más rápido si es urgente	Quedar mal priorizado o sufrir trato desigual por su grupo o edad	Bajo	Derecho a apelación y aviso de que se usa un sistema de apoyo
Operador (analista)	Organiza mejor su carga de trabajo	Confiar de más en el puntaje y perder criterio propio	Medio	Capacitación y reporte de errores o casos dudosos
Propietario institucional	Usa mejor los recursos de revisión	Responsabilidad legal y reputacional si el sistema causa daño	Alto	Aprueba el uso y decide continuar o retirar el sistema
Equipo de datos	Mejora el modelo con evidencia	Sesgos o errores técnicos no detectados	Medio	Auditorías periódicas y reporte de métricas al propietario

Proporcionalidad. (1) *Necesidad:* la alternativa sin modelo detecta más positivos (recall 0.859), pero marca el 73 % de la cola con una FPR de 0.559. El modelo mitigado marca el 52 % con una FPR de 0.235. El modelo solo aporta valor si la capacidad de revisión es limitada; si se pueden revisar más del 70 % de los casos, las reglas bastan y son menos invasivas. (2) *Minimización:* no hay identificadores directos, porque *validate_schema* los rechaza (prueba *test_privacy*), y *protected_group* no entra al modelo base. (3) *Intensidad:* el sistema solo ordena una cola; no decide elegibilidad ni intervenciones.

3. Obligación legal, marco voluntario y recomendación ética

El mandato pide separar lo que la ley exige de lo que se adopta de forma voluntaria y de lo que recomiendo por razones éticas. Como los datos son sintéticos, las obligaciones legales se aplicarían solo si el sistema operara con datos reales en la República Dominicana.

Tipo	Instrumento	Qué exige o propone	Aplicación en este caso
Obligación legal (RD)	Constitución de la República Dominicana (2015), arts. 39, 44 y 70	Igualdad y no discriminación; intimidad y acceso a los datos propios; acción de hábeas data	Una brecha sistemática contra un grupo exigiría corrección. La persona afectada debe poder conocer y corregir sus datos (apelación)
Obligación legal (RD)	Ley 172-13 de Protección Integral de los Datos Personales	Licitud y consentimiento, calidad de los datos, protección reforzada de datos sensibles, derechos de acceso, rectificación y supresión	*protected_group* y *age_band* serían datos personales; usar el grupo para entrenar la mitigación requeriría una base legal y una finalidad documentada
Referencia legal comparada (no aplica en RD)	Reglamento (UE) 2024/1689 de Inteligencia Artificial	Para sistemas de alto riesgo: gestión de riesgos, gobernanza de datos, registro y supervisión humana (art. 14)	Sirve de referencia de buenas prácticas si el sistema se usara para acceder a servicios públicos; no obliga en RD
Marco voluntario	NIST AI RMF 1.0 (2023)	Funciones GOVERN, MAP, MEASURE y MANAGE	Estructura el registro de riesgos y la evidencia (sección 4)
Marco voluntario	Recomendación de la OCDE sobre IA (OECD/LEGAL/0449)	Equidad, transparencia, robustez y rendición de cuentas	Fundamenta el aviso de uso del sistema, la apelación y el responsable identificado
Recomendación ética (propia)	Este expediente	Revisión humana de todos los casos; intervalos de confianza; soporte mínimo de 20; no usar el grupo al predecir; alternativa sin modelo como respaldo	Ninguna norma la exige de forma literal; la adopto porque el daño priorizado es no detectar un caso real

Nota: la clasificación es una interpretación académica, no un dictamen jurídico. Los artículos citados deben contrastarse con el texto oficial vigente antes de cualquier uso real.

4. Registro de riesgos y NIST AI RMF

Ocho riesgos con escenario, afectado, control, responsable y evidencia (*student_inputs/risk_register.csv*). La prioridad es probabilidad × impacto (escala 1–4), calculada por *scripts/lab11_impact.py*.

ID	Escenario	P	I	Prior.	Control	Responsable	Residual
R02	El analista acepta el puntaje sin revisar el caso (sesgo de automatización)	3	3	9	Capacitación y revisión obligatoria del caso antes de cerrarlo	Supervisor de analistas	Medio
R01	El modelo prioriza peor a un grupo protegido o a personas de 60+ (sesgo por subgrupo)	2	4	8	Auditoría de recall y FPR por subgrupo con brecha máxima de 0.16	Equipo de datos	Alto
R07	El puntaje se usa para decidir elegibilidad o intervención automática (uso fuera de alcance)	2	4	8	Política de usos prohibidos y auditoría del uso real	Propietario institucional	Alto
R03	Los datos cambian con el tiempo y el modelo pierde precisión (drift)	2	3	6	Validación temporal y monitoreo mensual del recall	Equipo de datos	Medio
R06	El operador no entiende por qué un caso tiene prioridad alta	3	2	6	Mostrar la explicación del puntaje en el tablero	Equipo de datos	Medio
R04	Reidentificación de personas o filtración de datos sensibles	1	4	4	Prohibir identificadores directos y restringir el acceso por rol	Equipo de datos	Medio
R05	El sistema responde lento o se cae y retrasa la revisión	2	2	4	Latencia máxima de 500 ms y respaldo con orden FIFO	Equipo de datos	Bajo
R08	La persona afectada no conoce o no usa la vía de apelación	1	3	3	Aviso claro y formulario de apelación accesible	Propietario institucional	Bajo

Lectura de los tres prioritarios. R02 (9), el sesgo de automatización, es el más probable: si el analista acepta el puntaje sin revisar, la supervisión humana deja de existir. Se controla con una revisión obligatoria registrada. **R01** (8), el sesgo por subgrupo, se midió en LAB12 y E07 (secciones 6 y 7). **R07** (8), el uso fuera de alcance, no depende del modelo sino de la política y la auditoría de accesos. R01 y R07 empatan en prioridad, pero considero R01 más urgente porque su daño recae en grupos protegidos. El orden orienta la atención, pero no reemplaza la revisión de cada escenario.

Función	Evidencia en el repositorio	Estado	Lo que el archivo no demuestra
GOVERN	Propietario y usos prohibidos (lab11_impact.yml, configs/governance.yml); RACI (raci.csv)	Documentado	Que la política se cumpla en la práctica
MAP	Finalidad, 4 partes interesadas y 8 riesgos (reports/lab11/)	Completo	Riesgos no previstos
MEASURE	Métricas globales, por grupo e interseccionales (reports/lab12/); mitigación e intervalos (reports/e07/)	Completo (E07)	Desempeño con datos reales ni deriva futura
MANAGE	Condición de retiro, apelación, decisión y respaldo sin modelo (DECISION_RECORD.md)	Definido	Que el retiro funcione: falta el runbook de LAB13

reports/lab11/rmf_summary.json todavía dice «MEASURE: LAB12 pending» porque se generó antes de LAB12. Lo conservo como registro histórico: un archivo que existe no equivale a un control eficaz.

5. Datos y diseño de la auditoría

Comprobación	Resultado	Lectura
Distribución de target	55.2 % positivos y 44.8 % negativos	Desbalance leve. Un clasificador que marque todo como positivo obtiene 0.575 de accuracy en la prueba; por eso accuracy no basta
Tamaño por grupo	G1 = 396 y G2 = 244; en prueba, G1 = 101 y G2 = 59	G2 tiene menos soporte y estimaciones menos estables
Prevalencia en prueba	G1 = 0.49 y G2 = 0.73	Explica buena parte de la diferencia en la tasa de selección; no es por sí sola un trato desigual
Corte temporal	Entrenamiento hasta el 2026-09-24 y prueba desde el 2026-09-25 (75/25)	Evalúa con casos futuros, como en el uso real, sin filtrar información del futuro
Variables excluidas	case_id, received_date, protected_group, target	Excluir el grupo no elimina el sesgo: zona y edad pueden actuar como variables proxy. Por eso el grupo se conserva para auditar

Métrica principal: la brecha de recall (TPR), porque el daño priorizado es no detectar un caso real. **Secundaria:** la brecha de FPR, porque una alerta falsa solo genera revisión adicional. **Tolerancias** (configs/governance.yml): recall ≥ 0.68 y brechas ≤ 0.16. **Soporte mínimo:** 20 observaciones por grupo interseccional. Es un criterio propio, porque el proyecto no fija ninguno; los grupos más pequeños se muestran, pero no se interpretan.

6. Auditoría global, por grupo e interseccional

Global (prueba, n = 160). Se comparan dos baselines (reglas sin modelo y todo positivo) con los dos modelos de LAB12:

Modelo	Accuracy	Recall	Precisión	FPR	Tasa de selección	Brecha recall	Brecha FPR
Baseline: todo positivo	0.575	1.000	0.575	1.000	1.000	0.000	0.000
Baseline: reglas sin modelo	0.681	0.859	0.675	0.559	0.731	0.084	0.087
Regresión logística	0.719	0.717	0.776	0.279	0.531	0.138	0.125
Árbol (max_depth = 5)	0.706	0.717	0.759	0.309	0.544	0.181	0.168

Por grupo. La logística cumple las tolerancias en el valor puntual (brechas 0.138 y 0.125). El árbol las supera (0.181 y 0.168) sin ganar utilidad.

Modelo	Grupo	n	Prevalencia	Recall	FPR	Tasa de selección	Precisión
Logística	G1	101	0.49	0.653	0.250	0.446	0.711
Logística	G2	59	0.73	0.791	0.375	0.678	0.850
Árbol	G1	101	0.49	0.633	0.269	0.446	0.689
Árbol	G2	59	0.73	0.814	0.438	0.712	0.833

El promedio oculta una falla localizada: el recall global (0.717) cumple, pero el de G1 (0.653) queda por debajo de 0.68. El modelo pierde más casos reales en G1, que es justamente el daño priorizado.

Interseccional (*protected_group* × *age_band*). Los grupos con n < 20 se muestran para no ocultarlos, pero no se interpretan.

Grupo	n	Recall log.	FPR log.	Recall árbol	FPR árbol	¿Se interpreta?
G1 · 18-29	18	0.750	0.143	0.750	0.214	**No** (n < 20)
G1 · 30-44	24	0.562	0.125	0.625	0.375	Sí
G1 · 45-59	35	0.588	0.389	0.647	0.278	Sí

Grupo	n	Recall log.	FPR log.	Recall árbol	FPR árbol	¿Se interpreta?
G1 · 60+	24	0.833	0.250	0.583	0.250	Sí
G2 · 18-29	11	0.875	0.000	1.000	0.000	**No** (n < 20)
G2 · 30-44	14	0.667	0.500	0.833	1.000	**No** (n < 20)
G2 · 45-59	8	1.000	0.000	0.667	0.000	**No** (n < 20)
G2 · 60+	26	0.765	0.556	0.765	0.556	Sí

Con soporte suficiente, **G1 · 30-44** y **G1 · 45-59** tienen el recall más bajo con la logística (0.562 y 0.588), y **G2 · 60+** tiene una FPR de 0.556: más de la mitad de sus negativos reciben una alerta falsa. Con n entre 24 y 35, un solo caso mueve el recall entre 4 y 8 puntos.

Incertidumbre. Bootstrap de 1000 remuestreos del conjunto de prueba (semilla 42), con intervalo percentil del 95 %:

Indicador	Logística base	Logística mitigada (sección 7)	Tolerancia
Brecha de recall	0.011 a 0.314	0.002 a 0.213	≤ 0.16
Brecha de FPR	0.005 a 0.398	0.005 a 0.373	≤ 0.16
Recall de G1	0.522 a 0.784	0.592 a 0.842	≥ 0.68

El valor puntual de la logística «cumple», pero el intervalo de su brecha de recall llega a 0.314: con 160 casos no se puede afirmar que la brecha real esté por debajo de 0.16. Esta es la razón principal para no desplegar el sistema sin límites.

Brecha no es prueba de discriminación causal. Una brecha observada obliga a investigar, pero no demuestra discriminación por sí sola, por cuatro razones. (1) Las prevalencias difieren (0.49 frente a 0.73), lo que mueve la tasa de selección y la FPR. (2) Las muestras son pequeñas y los intervalos amplios. (3) El modelo no usa el grupo, pero puede reproducir diferencias a través de variables proxy como la zona o la edad. (4) Fairlearn mide asociaciones; afirmar una causa exigiría conocer cómo se generó la etiqueta.

7. Mitigación y trade-offs

Comparé tres mitigaciones con la logística base (*scripts/e07_mitigation.py*). Las dos primeras bajan el umbral de decisión sin usar el grupo. La tercera es **ExponentiatedGradient** con restricción de paridad de recall (Agarwal et al., 2018): usa el grupo solo durante el entrenamiento, no al predecir.

Variante	Accuracy	Recall	FPR	Tasa sel.	Brecha recall	Brecha FPR	Recall G1	FPR G2
Logística base (umbral 0.50)	0.719	0.717	0.279	0.531	0.138	0.125	0.653	0.375
Logística, umbral 0.45	0.712	0.739	0.324	0.562	0.140	0.149	0.673	0.438
Logística, umbral 0.40	0.731	0.848	0.426	0.669	0.067	0.096	0.816	0.500
ExponentiatedGradient, paridad de recall	0.744	0.728	0.235	0.519	0.030	0.101	0.714	0.312
Referencia: reglas sin modelo	0.681	0.859	0.559	0.731	0.084	0.087	0.898	0.625

Bajar el umbral a 0.40 sube el recall a 0.848 y cierra la brecha a 0.067, pero la FPR pasa de 0.279 a 0.426 (la de G2 llega a 0.500). Más alertas falsas aumentan la carga de revisión y el riesgo de sesgo de automatización (R02). **ExponentiatedGradient** consigue el mejor equilibrio: reduce la brecha de recall de 0.138 a 0.030, sube el recall de G1 de 0.653 a 0.714, baja la FPR global a 0.235 y no pierde accuracy (0.744).

Costos de la mitigación elegida. (1) Usa *protected_group* al entrenar: con datos reales, eso es tratamiento de datos sensibles y necesitaría una base legal (sección 3). (2) Es un clasificador aleatorizado: el mismo caso puede recibir otra predicción con otra semilla, lo que complica explicar y apelar. Fijo la semilla y la revisión humana cubre todos los casos. (3) No resuelve todos los subgrupos:

Grupo (n ≥ 20)	n	Recall base → mitigado	FPR base → mitigado
G1 · 30-44	24	0.562 → 0.688	0.125 → 0.125
G1 · 45-59	35	0.588 → 0.588	0.389 → 0.222
G1 · 60+	24	0.833 → 0.917	0.250 → 0.333
G2 · 60+	26	0.765 → 0.765	0.556 → 0.444

G1 · 45-59 se queda en un recall de 0.588: la mitigación global no corrige este subgrupo, que necesita investigación propia (datos, variables proxy y umbral).

Costo computacional (Green AI).

Modelo	Entrenamiento	Tamaño serializado	Comentario
Logística (LAB12)	1.32 s*	3.6 KB	Suficiente y explicable
Árbol (LAB12)	0.16 s	7.9 KB	Doble de tamaño, sin ganar utilidad y con peores brechas
ExponentiatedGradient (E07)	1.39 s	No serializado	Unas 11 veces el tiempo de la logística (que tardó 0.12 s en la misma ejecución); sigue siendo despreciable en CPU

*La primera ejecución de LAB12 incluye la carga del entorno. Todos los costos son mínimos; el árbol se descarta porque su complejidad no se justifica, no por su costo.

8. Decisión final: modificar y limitar

Opción	¿Se elige?	Razón
Desplegar	No	El intervalo de la brecha de recall de la logística base llega a 0.314, el recall de G1 está bajo la tolerancia y los datos son sintéticos
Modificar	**Sí**	Se sustituye la logística base por ExponentiatedGradient con paridad de recall: brecha 0.030, recall de G1 0.714 y menos alertas falsas
Limitar	**Sí**	Solo piloto: revisión humana de todos los casos, reglas sin modelo como comparador y respaldo, sin uso para elegibilidad ni intervención
No utilizar	No, por ahora	Las reglas siguen disponibles; se pasa a «no utilizar» si se cumple la condición de retiro o si el piloto no mejora a las reglas con la capacidad real

Condiciones del piloto. (1) El analista revisa todos los casos y queda registro (control de R02). (2) Cada mes se informa el recall de G1, el de G1 · 45-59 y la FPR de G2 · 60+, con intervalos. (3) Se compara con las reglas sin modelo según la capacidad real de revisión. (4) La política de usos prohibidos queda firmada (R07). **Para pasar a desplegar:** que el límite superior del intervalo de las brechas quede por debajo de 0.16 con más datos, que G1 · 45-59 alcance un recall de 0.68 y que exista una base legal para usar el grupo al entrenar. **Retiro:** suspender si el recall baja de 0.68, si la brecha entre grupos supera 0.16 o si se detecta un uso indebido o un daño. Decide el propietario institucional; registro completo en *reports/lab11/DECISION_RECORD.md*.

9. Errores encontrados y cómo los resolví

Error	Causa	Solución
lab11_impact.py fallaba con *SyntaxError: unterminated string literal*	El script base tenía saltos de línea reales dentro de una cadena entre comillas	Usar *\n* en la cadena (línea 11)
El registro de decisión volvía a la plantilla	*lab11_impact.py* reescribe DECISION_RECORD.md en cada ejecución	Escribir la decisión después de la última ejecución; aviso en el README
pytest mostraba *PytestCacheWarning: Access is denied* (E2)	La carpeta está sincronizada con OneDrive	No afecta a las pruebas (10 de 10 pasan); se puede ejecutar con *-p no:cacheprovider*
git push fallaba con «Repository not found»	El remoto apuntaba a una URL de ejemplo	Integrar el proyecto en el repositorio del curso, en Unidad IV/Ejercicio 07
El DOI de la OCDE de la guía (10.1787/cc2e1d3e-en) devuelve 404	Identificador no válido en doi.org	Citar la Recomendación desde su página oficial (OECD/LEGAL/0449)
ExponentiatedGradient rechazó *random_state*	fairlearn 0.12 no lo acepta en el constructor	Pasar la semilla en *predict*; dos ejecuciones dieron salidas idénticas

10. Límites

(1) Los datos son sintéticos: las cifras no se pueden trasladar a poblaciones reales. (2) El conjunto de prueba tiene 160 casos, y 5 de los 8 grupos interseccionales tienen menos de 20 observaciones. (3) La mitigación se eligió y se evaluó sobre el mismo conjunto de prueba, sin una partición de validación aparte, así que su ventaja puede estar sobreestimada. (4) La regla sin modelo es una concreción mía de la alternativa de LAB11, no una regla validada. (5) La probabilidad y el impacto del registro de riesgos son juicios, no mediciones. (6) El análisis normativo no es asesoría jurídica. (7) No se midió la deriva temporal más allá de un solo corte.

11. Artefactos, pruebas y Git

Ruta	Contenido
student_inputs/	lab11_impact.yml, stakeholders.csv, risk_register.csv y lab12_decision.yml (editables)
reports/lab11/	risk_register_scored.csv, rmf_summary.json y DECISION_RECORD.md (con la actualización de E07)
reports/lab12/	global_metrics.json, fairness_by_group.csv y fairness_intersectional.csv (logística y árbol) y AUDIT_REPORT.md
reports/e07/	mitigation_comparison.csv, bootstrap_gaps.json, expgrad_intersectional.csv y run_log.txt (salida de consola)
src/inf8239_u04/mitigation.py	Reglas sin modelo, umbral, ExponentiatedGradient e intervalos bootstrap
scripts/e07_mitigation.py	Genera los resultados de reports/e07/
tests/	12 pruebas: datos, privacidad, impacto, equidad, modelo, gobernanza, app y mitigación
README.md, docs/AI_USE_DECLARATION.md	Índice del expediente, cómo reproducirlo y declaración de uso de IA

```
uv sync --frozen
uv run pytest -q
uv run python scripts/lab12_audit.py --model logistic
uv run python scripts/lab12_audit.py --model tree
uv run python scripts/validate_lab12_decision.py
uv run python scripts/e07_mitigation.py
```

Pruebas. Las 12 pasan. Las 10 del proyecto base comprueban el esquema de datos, el rechazo de identificadores directos, el cálculo de prioridad y el rechazo de *REPLACE*, que las métricas de equidad están acotadas, que las predicciones son binarias, que una puerta fallida exige revisión y que el RACI tiene responsable. Las 2 nuevas verifican que bajar el umbral nunca reduce los positivos detectados y que los intervalos bootstrap están ordenados y

acotados. **Git.** El historial del repositorio muestra un commit por etapa (LAB11, LAB12 y E07).

12. Uso de inteligencia artificial

Herramienta	Claude Code (modelo Claude Opus 5.5, de Anthropic), desde Visual Studio Code, en octubre de 2026, como apoyo durante el ejercicio.
Mi trabajo	Ejecuté LAB11 en mi equipo (E1–E3), revisé y modifiqué los insumos de LAB11 y LAB12, hice los commits y el push, revisé las cifras y la decisión final, y revisé este informe.
Prompts relevantes (resumidos)	«Ponte en contexto de este laboratorio […] solo entiende todo»; «¿Qué valores me pide el maestro que ponga aquí? Explícame por qué»; «Completa todo esto y pásame los comandos para yo correrlo, commit y push» (LAB12); «Actualicemos todo acorde a este ejercicio 07 […] utiliza el formato del PDF adjunto […] verifica que el PDF no quede con datos del modelo template».
Apoyo recibido	Trabajamos en conjunto: yo dirigí la revisión y validé cada cambio. La herramienta propuso borradores de los insumos de LAB11 y LAB12, corrigió el error de sintaxis del script, ejecutó las auditorías, escribió el módulo de mitigación y sus pruebas, y redactó los borradores del README, el registro de decisión, la declaración de IA, este informe y el anexo.
Verificaciones	Las 12 pruebas pasan. Dos ejecuciones de e07_mitigation.py dieron salidas idénticas. Las cifras del informe se leen de los CSV y JSON del repositorio al generar el PDF. Los DOI de NIST, Fairlearn, Hardt et al. y Agarwal et al. resuelven en doi.org, y la página de la OCDE responde.
Correcciones realizadas	(1) El DOI de la OCDE de la guía no resuelve y se citó la página oficial. (2) La lectura «la logística cumple las brechas» se matizó con intervalos bootstrap. (3) La alternativa sin modelo se midió en lugar de solo enunciarla. (4) Recorté la barra de estado de E3, que mostraba un correo corporativo.
Valores y decisiones	La IA no decidió los valores del análisis. El daño priorizado, la tolerancia, el soporte mínimo de 20, la clasificación normativa y la decisión de modificar y limitar los revisé y asumo como míos.
Responsabilidad	Revisé el contenido final, puedo explicar cada fragmento del código y asumo la responsabilidad de lo entregado.

13. Fuentes

Agarwal, A., Beygelzimer, A., Dudík, M., Langford, J., & Wallach, H. (2018). *A reductions approach to fair classification* (arXiv:1803.02453). arXiv. https://doi.org/10.48550/arXiv.1803.02453

Constitución de la República Dominicana. (2015). Proclamada el 13 de junio de 2015.

Hardt, M., Price, E., & Srebro, N. (2016). *Equality of opportunity in supervised learning* (arXiv:1610.02413). arXiv. https://doi.org/10.48550/arXiv.1610.02413

Ley n.º 172-13 que tiene por objeto la protección integral de los datos personales asentados en archivos, registros públicos, bancos de datos u otros medios técnicos de tratamiento de datos. (2013). Congreso Nacional de la República Dominicana.

National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* (NIST AI 100-1). https://doi.org/10.6028/NIST.AI.100-1

OECD. (2019, revisada en 2024). *Recommendation of the Council on Artificial Intelligence* (OECD/LEGAL/0449). https://legalinstruments.oecd.org/en/instruments/OECD-LEGAL-0449

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial. *Diario Oficial de la Unión Europea*, L, 12.7.2024. http://data.europa.eu/eli/reg/2024/1689/oj

Weerts, H., Dudík, M., Edgar, R., Jalali, A., Lutz, R., & Madaio, M. (2023). *Fairlearn: Assessing and improving fairness of AI systems* (arXiv:2303.16626). arXiv. https://doi.org/10.48550/arXiv.2303.16626