Ejercicio 08: Expediente de gobernanza y simulacro

INF-8239 Ciencia de Datos II, Unidad 04 (U04.E08)

Estudiante	Roque Alexis Ventura Vallejo
Matrícula	100805873
Repositorio	github.com/RoqueVentura/UASD-Maestria-Ciencia-De-Datos, Ciencia de datos II/Unidad IV/Ejercicio 08
Evidencia	U04_E08_Evidencias_Roque_Ventura.pdf (abrir en GitHub)
Base	LAB13, proyecto INF8239_U04_Gobernanza_DSS_Proyecto_Base_uv
Decisión final	**Modificar y limitar** (sección 6)

Caso. El Territorial Review DSS prioriza casos territoriales sintéticos para revisión humana. Solo recomienda un orden y presenta evidencia; la decisión es humana. Las cifras de este informe se leen de los archivos editables del repositorio (CSV, YAML y JSON).

1. Obligación legal, marco voluntario y recomendación ética

Tipo	Instrumento	Aplicación en este caso
Obligación legal	Ley 172-13 de Protección de Datos Personales y Constitución de la República Dominicana	Con datos reales, *protected_group*, *age_band* y *zone* serían datos personales: exigirían base legal, minimización, conservación limitada y derechos de acceso y rectificación. Con datos sintéticos la obligación no se activa
Marco voluntario	NIST AI RMF 1.0; Model Cards; Datasheets	Estructuran la RACI y los traspasos (GOVERN), el inventario (MAP), el monitoreo (MEASURE), el runbook y el simulacro (MANAGE), y la documentación del modelo y de los datos
Recomendación ética	Criterio propio	Revisión humana de todos los casos; evidencia de incidentes sin filas de casos; brechas solo con 20 o más casos por grupo

2. Inventario, minimización y retención

Campos	Uso	Minimización
name, document_number, email, phone	Ninguno	No se recolectan; el contrato rechaza el lote antes de predecir
case_id, received_date	Trazabilidad y corte temporal	Fuera del modelo; la fecha se agrega a mes en el monitoreo
protected_group	Solo auditoría de equidad	Fuera del modelo; acceso restringido al equipo de auditoría
age_band	Modelo y auditoría	Tramos de edad, no fecha de nacimiento
zone, previous_incidents, infrastructure_score, exposure	Modelo	4 zonas amplias; conteos e índices agregados; zone se vigila como proxy
target	Entrenamiento y evaluación	Resultado de la revisión humana

Artefacto	Retención	Responsable
Dataset del piloto (entrenamiento y prueba)	Mientras dure el piloto y 12 meses tras el retiro	Ingeniero de datos
Puntajes y prioridad por caso	12 meses o hasta cerrar la última apelación del caso (lo que ocurra después)	Ingeniero de ML
Modelo serializado	Versión vigente y las 2 anteriores para rollback	Ingeniero de ML
Decisión de despliegue y reportes de equidad	Vida del sistema y 3 años después del retiro	Científico de datos

Artefacto	Retención	Responsable
Reportes de monitoreo	Vida del sistema y 3 años después del retiro	Ingeniero de ML
Evidencia de incidentes	3 años desde el cierre del postmortem	Científico de datos
Registro de casos revisados	24 meses	Supervisor de analistas
Registro de accesos	12 meses	Ingeniero de ML
Bitácora de apelaciones	24 meses tras la resolución	Supervisor independiente de apelaciones

Detalle por campo en *student_inputs/data_inventory.csv* y por artefacto en *student_inputs/retention_policy.csv*. Una prueba verifica que el inventario coincida con el contrato de datos y con las variables del modelo.

3. Datasheet y Model Card trazables

docs/DATASET_CARD.md describe motivación, composición (640 casos, 0 faltantes), preprocesamiento, usos y retención. *docs/MODEL_CARD.md* registra la versión **logistic-sklearn1.9.1-054494c**, las puertas, los grupos, el monitoreo y el simulacro. Cada cifra apunta a su archivo de origen.

Puerta	Valor	Umbral	Resultado
Recall global	0.717	≥ 0.68	Pasa
Brecha de recall	0.138	≤ 0.16	Pasa
Brecha de FPR	0.125	≤ 0.16	Pasa
Latencia y tamaño	0.03 ms; 3.6 KB	≤ 500 ms; ≤ 1024 KB	Pasa
Recall G1 (vigilancia)	0.653	0.68	**Bajo**

4. RACI y traspaso entre roles

Cada actividad tiene un solo Accountable (*student_inputs/raci.csv*). Los traspasos (*student_inputs/handoffs.csv*) definen entregable, criterio de aceptación y firma; una prueba exige que firme el Accountable de la actividad y que la evidencia exista.

Traspaso	De → a	Firma (Accountable)
1. Datos a modelado	Ingeniero de datos → Científico de datos	Líder del equipo de datos
2. Modelado a auditoría	Científico de datos → Líder del equipo de datos	Líder del equipo de datos
3. Auditoría a decisión	Científico de datos → Responsable de producto	Dirección de Gestión de Riesgo Territorial
4. Decisión a despliegue	Responsable de producto → Ingeniero de ML	Dirección de Gestión de Riesgo Territorial
5. Despliegue a operación	Ingeniero de ML → Analistas territoriales	Líder del equipo de datos
6. Operación a monitoreo	Analistas territoriales → Ingeniero de ML	Supervisor de analistas
7. Monitoreo a incidente	Ingeniero de ML → Dirección de Gestión de Riesgo Territorial	Dirección de Gestión de Riesgo Territorial
8. Incidente a cierre	Científico de datos → Dirección de Gestión de Riesgo Territorial	Dirección de Gestión de Riesgo Territorial
9. Apelación a revisión	Supervisor independiente de apelaciones → Analistas territoriales	Dirección de Gestión de Riesgo Territorial
10. Retiro a eliminación	Responsable de producto → Ingeniero de datos	Dirección de Gestión de Riesgo Territorial

5. Monitoreo, runbook y simulacro

configs/monitoring.yml define señales, frecuencia, responsable y acción. Resultado mensual del periodo de prueba con el modelo base y con el modelo mitigado de E07 (EG):

Mes	n (G1/G2)	Recall	Brecha recall	Brecha FPR	Brecha recall EG	Brecha FPR EG
2026-10	54 (35/19)	0.643	*0.000**	*0.038**	*0.071**	*0.057**
2026-11	54 (33/21)	0.710	0.175	0.039	0.046	0.186
2026-12	46 (30/16)	0.793	*0.333**	*0.433**	*0.187**	*0.517**

* Menos de 20 casos en un grupo: no se interpreta. Octubre tiene recall 0.643 (< 0.68) y noviembre una brecha de recall de 0.175 (> 0.16). El modelo mitigado la reduce a 0.046, pero la brecha de FPR sube a 0.186.

Simulacro (*scripts/e08_incident_drill.py*): previous_incidents = 0 en la zona Oeste por fallo de ingesta.

Métrica	Lote correcto	Lote con fallo	Lote corregido
Recall global	0.717	0.522	0.717
Brecha de recall	0.138	0.199	0.138
Recall G1 / G2	0.653 / 0.791	0.429 / 0.628	0.653 / 0.791
Decisión	GO	**REVIEW** (recall, recall_gap)	GO

Fase	Resultado
Detección	Contrato: un lote con *email* fue rechazado. PSI global 0.194 (no alcanza 0.25); ceros en Oeste: 5 % en la referencia frente a 100 % en el lote. Las puertas pasan a REVIEW
Contención y rollback	REVIEW, cola en FIFO y lote en cuarentena (runbook). Con el lote corregido vuelve a GO; la reactivación requiere firma de la Dirección
Evidencia	9 archivos con SHA-256, versión y hash del modelo, sin filas de casos (*reports/e08/incident_drill/*)
Comunicación	Interna y a representantes de personas afectadas, según el runbook (*docs/RUNBOOK.md*)
Postmortem	Causa, impacto y acciones con responsable y fecha (*reports/e08/POSTMORTEM.md*)

6. Decisión final

Opción	Decisión	Razón
Desplegar	No	El GO agregado oculta fallas por mes, y un fallo de ingesta baja el recall a 0.522. Los datos son sintéticos
Modificar	**Sí**	Modelo mitigado de E07, regla de calidad de datos por zona y monitoreo mensual de recall y FPR
Limitar	**Sí**	Solo piloto, con revisión humana de todos los casos y FIFO como respaldo
No utilizar	No, por ahora	Se aplica si se cumple la condición de retiro de LAB11

La Dirección de Gestión de Riesgo Territorial (Accountable) firma el despliegue, la suspensión y la reactivación.

7. Pruebas y Git

32 pruebas aprobadas: contrato de datos, privacidad, equidad, gobernanza, app, inventario, retención, traspasos, monitoreo y simulacro. El historial de commits y las etiquetas *u04-lab13* y *u04-e08* están en el repositorio. La salida de consola está en *reports/e08/run_log.txt* y en el anexo.

```
uv sync --frozen
uv run pytest -q
uv run python scripts/e08_monitoring.py
uv run python scripts/e08_incident_drill.py
```

8. Uso de inteligencia artificial

Herramienta	Claude Code (Claude Opus 5.5, de Anthropic) en Visual Studio Code, octubre de 2026.
Mi trabajo	Ejecuté LAB13 en mi equipo y preparé las capturas de evidencia (anexo, E1–E7). Dirigí el trabajo con la IA: indiqué qué verificar contra el manual, el mandato y la rúbrica, definí el alcance y elegí el repositorio y la carpeta de entrega. Revisé cada propuesta antes de aceptarla y pedí cambios cuando fue necesario. Revisé e implementé los artefactos y sus valores (retención, traspasos, umbrales y decisión final). Ejecuté las pruebas y los scripts, hice los commits y las etiquetas, detecté los errores al integrar el proyecto en el repositorio del curso, los resolví con la IA e hice el push.
Prompts relevantes	Verificar LAB13 contra el manual y corregir lo faltante. Completar E08 según el mandato y la rúbrica. Generar el anexo con mis capturas. Diagnosticar los errores al integrar el repositorio.
Apoyo recibido	Propuestas de código (monitoreo, simulacro, pruebas y generador del PDF) y de redacción, que revisé y ajusté; diagnóstico de errores de Git.
Verificaciones	Las 32 pruebas pasan. Las cifras del informe se leen de los CSV y JSON; las comparé con *run_log.txt*.
Correcciones	(1) La alerta mensual omitía el recall cuando un grupo tenía poco soporte. (2) El PSI global no detectó el fallo del simulacro; se documentó y se añadió el perfil por zona. (3) Se recortó de las capturas una cuenta corporativa. (4) Se corrigieron cifras de la Model Card, el datasheet y el postmortem para que coincidan con sus archivos de origen.
Responsabilidad	Los valores y las conclusiones son míos. Puedo explicar cada parte y asumo la responsabilidad de lo entregado.

9. Referencias

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86–92. https://doi.org/10.1145/3458723

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). https://doi.org/10.1145/3287560.3287596

National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* (NIST AI 100-1). https://doi.org/10.6028/NIST.AI.100-1