

Ejercicio 01 · Dataset público y SVM reproducible

INF-8239 Ciencia de Datos II · Unidad 01 · U01.E01

Estudiante	Roque Alexis Ventura Vallejo
Matrícula	100805873
Repositorio	github.com/RoqueVentura/UASD-Maestria-Ciencia-De-Datos (carpeta <i>Ciencia de datos II/Unidad I</i>)
Contenido	notebooks/, src/, tests/, reports/, docs/, requirements.txt, README.md

1. Dataset seleccionado

Campo	Detalle
Dataset	HCV Data : analíticas de sangre de donantes y de pacientes con hepatitis C
Procedencia	UCI ML Repository · Lichtinghagen, Klawonn y Hoffmann (Hannover Medical School) · DOI 10.24432/C5D612
Licencia	CC BY 4.0 (uso académico permitido, con cita) · aprobado por el docente
Descarga	CSV directo de UCI, sin Drive personal (src/inf8239_u01/data.py)
Pregunta	¿Puede una SVM identificar enfermedad hepática a partir de una analítica de rutina, para priorizar la revisión?
Unidad / target	Un paciente o donante con una analítica · hepatopatía: <i>si</i> (hepatitis, fibrosis o cirrosis, 75) vs. <i>no</i> (donante, 533)
Error más costoso	Falso negativo: un paciente enfermo clasificado como sano

Comparación de candidatos (detalle en docs/ficha_dataset.md):

Criterio	A · HCV Data (elegido)	B · Maternal Health Risk
Filas / columnas	615 × 14	1014 × 7, pero solo 452 filas únicas (55 % duplicadas)
Target	5 categorías, binarizado 75 / 533	3 clases (406 / 336 / 272)
Ausentes	31 celdas (ALP, CHOL...)	Ninguno
Riesgo	Fuga por el identificador (tratada)	No alcanza 500 filas únicas; HeartRate = 7

2. Auditoría y prevención de fuga

- Sin filas duplicadas. Hay 31 celdas ausentes, concentradas en pacientes enfermos (ausencia informativa); se imputan con la mediana **dentro del pipeline**.
- Fuga detectada**: el identificador Unnamed: 0 está ordenado por clase (donantes 1-533, enfermos 541-615) y por sí solo predice el target con F1 = 1.0. Se excluye.
- También se excluyen Category (fuente del target) y las 7 filas *suspect Blood Donor* (etiqueta incierta). Ninguna exclusión se decidió por su efecto en la métrica.
- El diccionario de datos (significado, unidad, disponibilidad, transformación y riesgo) está en docs/diccionario_datos.md.

3. Resultados principales

Partición estratificada 80/20 (random_state=42). La línea base y la SVM comparten la partición y el preprocesamiento (ColumnTransformer: imputación, estandarización y one-hot).

Modelo (conjunto de prueba)	F1-macro	Accuracy	Recall <i>si</i>	FN	FP
HCV · Dummy (clase más frecuente)	0.467	0.877	0.00	15	0
HCV · SVM RBF (C=1, gamma=scale)	0.844	0.943	0.60	6	1
LAB01 Breast Cancer · Dummy	0.387	—	—	—	—
LAB01 Breast Cancer · SVM ajustada (C=10, gamma=0.01; CV 0.974 ± 0.018)	0.981	0.982	—	1*	1*

* En LAB01, 1 maligno clasificado como benigno y 1 benigno como maligno. FN/FP de HCV respecto a la clase *si* (enfermo).




Figura 1. HCV: SVM en prueba. Detecta 9 de 15 enfermos y deja escapar 6 (FN).




Figura 2. LAB01 (Breast Cancer): SVM base en prueba, con 2 errores en 114 casos.

4. Reproducibilidad: código, pruebas y Git

- **src/**: `build_svm()` (pipeline sin fuga) y `download_csv()` (descarga validada).
- **tests/**: 7 pruebas aprobadas (`python -m pytest -q`). Cubren el entorno, el modelo (3) y el contrato de datos (3: dataset no vacío, columnas requeridas, target sin ausentes con al menos dos clases).
- **README**: instalación en `.venv`, descarga reproducible, target, métrica y ejecución. Entorno: Windows 11, Python 3.10.11, scikit-learn 1.7.2.
- **Git**: commits por etapa (entorno, experimento SVM, dataset con contrato, auditoría y notebook ejecutado). Los notebooks 01 y 02 se ejecutaron de principio a fin.

5. Conclusión

Se propone el conjunto *HCV Data* del repositorio UCI (CC BY 4.0, DOI 10.24432/C5D612) para apoyar una decisión de tamizaje: priorizar para revisión hepatológica las analíticas sanguíneas de rutina que sugieran enfermedad hepática. La unidad de análisis es un paciente o donante con una analítica y sus datos de edad y sexo. El target hepatopatía agrupa hepatitis C, fibrosis y cirrosis (si) frente a donantes sanos (no). Se eligió frente a *Maternal Health Risk*, que, aunque tiene 1014 filas, solo contiene 452 observaciones únicas (55 % de duplicados) y valores fisiológicamente imposibles, como una frecuencia cardíaca de 7 lpm.

La auditoría encontró tres problemas que condicionan el modelado. Primero, **el identificador Unnamed: 0 está ordenado por clase**: los donantes ocupan las filas 1-533 y los enfermos las 541-615, de modo que un árbol entrenado solo con ese número alcanza un F1-macro de 1.0. Es una fuga perfecta, sin significado clínico, y por eso se excluyó. Segundo, **los valores ausentes no son aleatorios**: 19 de las 26 filas incompletas pertenecen a pacientes enfermos, sobre todo en ALP y CHOL. Se imputan con la mediana dentro del pipeline, para que la imputación solo aprenda del conjunto de entrenamiento. Tercero, **el desbalance es fuerte**: 533 donantes frente a 75 enfermos (12 %). Además, se retiraron las 7 filas de "donante sospechoso", porque su etiqueta es incierta y no sirve ni como positivo ni como negativo, y la columna *Category*, por ser la fuente del target. Ninguna exclusión se decidió por su efecto en la métrica.

Con la misma partición estratificada (80/20, `random_state=42`) y el mismo preprocesamiento (imputación, estandarización y one-hot dentro de un `ColumnTransformer`), la línea base de la clase más frecuente obtuvo un F1-macro de 0.467 y una SVM RBF sin ajustar ($C=1$, $\gamma=\text{"scale"}$) obtuvo 0.844. La exactitud de la SVM (0.94) parece excelente, pero oculta el problema principal: de 15 enfermos en el conjunto de prueba, el modelo detectó 9 y **pasó por alto 6** ($\text{recall de si} = 0.60$), frente a una sola falsa alarma entre 107 donantes. El modelo comete sobre todo el error más costoso del caso, porque un falso negativo deja sin seguimiento a un paciente que podría progresar hacia la cirrosis.

Con clases desbalanceadas, la accuracy no basta: el F1-macro debe acompañarse del recall de la clase positiva. Como siguiente paso se propone ajustar `class_weight="balanced"`, `C` y `gamma` mediante `GridSearchCV` con validación cruzada estratificada sobre el conjunto de entrenamiento, y valorar el umbral de decisión a partir de las probabilidades. El conjunto de prueba se reservará para la evaluación final.

El dataset fue aprobado por el docente. Las limitaciones principales son el tamaño reducido de la clase positiva (15 casos en prueba, así que un solo acierto cambia el recall en casi 7 puntos), el origen de los datos en un único centro y la falta de unidades oficiales en la ficha de UCI. El trabajo es académico y no constituye un diagnóstico médico.